

1/4/20 - '3

#2 11377

- kipN

מכל היותר מילויים נקיים הינו?

(תפקידו של מנהל המוסד כמי שמייצג את המוסד ביחס ללקוחות,

לעתות אחדים מושג יפה, ?ML גנוב בזען נסחף מהתוכנה. נאכלה ברגע גנובו נסחף,

בדראן הדרה. אין לנו מושג מהי הדרה. מושג זה לא ניתן לארח בדראן.

תכליתנו היא לסייע לך בפתרון בעיות מילוי ופער.

• תְּנִזֵּן (תְּנִזֵּן)

: וְהִנֵּה תָּמִיד תַּעֲשֶׂה לְפָנֵינוּ ? נְגִינָה

? P3N15 3312 °

? የብንና ማማሪ የተደረገ የነ

? 31NSG UNBGD PK 0831. י'lc .
, 031C UNBGD 0831. י'lc .

... 831, 305 831N ʃəkɪf, pəθəθɪn pɪθəθɪn aθəθf, ɣ3, nɪn əθ ſɪθ' sɪθ.. kɪθɪnθ

* **הצגה 3.16 (ב) מוקדם:** רכבה גוף נגדי ל- γ ביחס ל- α , הוכח, פרום

$\vdash \neg \rightarrow \forall x \in \mathcal{X}, \text{All } \mathcal{C}(x) \text{ is son kid}$ domain set \rightarrow top \mathcal{X}

תְּמִימָנָה נְבוֹזָר מִגְּדֹלָה גַּתְּנִים נֶגֶב קְרֵתָה גַּתְּנִים (x,y) \in X \times Y

(Supervised learning) የሚገኘውን አይነት ይጠናል

Feature Vectors, Images, Time Series, Geo Data, Compound : Domain Sets

Classification = $\{\pm 1\}$, Multiclass Classification = $\{1,..,K\}$, : Label Sets

Regression = R, Ranking, Matching, Link prediction $\xrightarrow{\text{LINKP}}$ $\begin{pmatrix} \text{IP} \\ \text{P}, \text{eP} \\ \text{P}, \text{eP} \end{pmatrix}$

جواب

{OK, fraud} - 4, 12PS, 6 re features - X : Create visual representation: ANNEN

Multiclass classification

• $\{OK, \text{spam}\} \leftarrow \text{text, } p, \text{enc-}X : \text{acs, } \text{key, } \text{mu.o}$

וְהַקְרָבָה אֲלֵיכֶם - יְהוָה, וְיִמְרָא בְּכָל־עַמּוֹתֶךָ: כִּי־בְּרִית־יְהוָה כְּבָר־עָמַד.

רְגִסְטְּרוֹנְסִיָּה \leftarrow נְתַנוּ לְמִינְגֵּר $-Y$ מִפְרָשׁ תְּכֻלָּה $-X$ - 13]

לפניהם נקבעו נתונים אינטראקטיביים (training data) - מינימום 2 נקודות. נסמן f כפונקציית מAPPING בין הנקודות לנתונים. נסמן x_i כערך ה- i -י בdataset, ו- y_i כערך ה- i -י בdataset. נסמן $(x_i, f(x_i))$ כערך ה- i -י בdataset.

• בנין מונחים היבטים לפניהם ההשראת ההשראת ההשראת ההשראת

23. Nfce proto

וילען ה' מילאנו יפנ' אל פונט. 1 : Batch learning •

$\{(x_i, y_i)\}_{i=1}^m$: training data poolic 2

Next problem, bind the μ_{N} term.

$$\{h(\tilde{x}_j) = \hat{y}_j\}_{j=1}^K : \text{וגנ } \{\tilde{x}_j\}_{j=1}^K : \text{ו } \text{וגנ } \text{וגנ } \text{וגנ } .$$

הו מונח שפירושו למידה מקוונת או אונליין (Online learning) הוא:

: $i = 1, 2, \dots, n$ | \tilde{f}_N $\rho_{Y|XN}$.2

$\hat{y}_i = h_{i-1}(x_i) \rightarrow \text{a label} \rightarrow \text{a purpose}$ (iii)

.hi : הַיְלָדִים אל רַבְעֵבָן yi, yi יְהוָה יְהוָה יְהוָה (iv)

$(\{(x_i, y_i)\}_{i=1}^m)$ tables - 1 min. \geq for N training set \Rightarrow Supervise

$\left\{ \begin{array}{l} \text{רוכסן: } \{x_i\}_{i=1}^m \\ \text{clusters - f} \\ \text{לכון רוכסן} \\ \text{ל. נאדרן f_b} \end{array} \right\} \leftarrow \text{Tables}_{\text{לכון}} \text{like training set} \Rightarrow \text{Un-Supervised.}$

$X = \mathbb{R}^d$: use supervised learning + batch learning : p plots ↫

$y = R$ inc (input) $\{\pm 1\} = y$, (features vectors inc)

• unsupervised learning - 1 (näytööpäätösin) $Y = [K]$ py 2020

למה לא מודים לנו שפה? למה לא מודים לנו שפה?

הנ'ם, prepn data-sets יתקיימו, prepn data-sets יקיים

• ML סע פִּזְבִּין, ML ננָּהָר מִלְּבָד. רכיז מיליבן IK פִּזְבִּין IK פִּזְבִּין גַּת צְבָא
IK פִּזְבִּין גַּת צְבָא (... אֶלְעָזָר בָּנֵי...) גַּת צְבָא IK פִּזְבִּין גַּת צְבָא
... פִּזְבִּין גַּת צְבָא פִּזְבִּין גַּת צְבָא, סִינְסִינְטִיסִיס אֲמֹרָה.

כרכורה גוף�ר

Lifetime value → $\pi^c \times \text{Avg PSpn} \times \text{Avg PSpG} \times U^c = \135 per customer

: batch learning \rightarrow 3PNM. (הנתקת ה-NN מ-3PNM) פותח מנגנון למדת ניטרול (feature vector: פונקציית מילוי) על מנת למדת טעינה (training data \rightarrow).

$\gamma = \mathbb{R}$, $\chi = \mathbb{R}^d$: $\mu_0, \dots, \mu_N, \sigma_0, \dots, \sigma_{N-1}$ $\in \mathcal{P}_1(\mathbb{R}^d)$ μ_0, \dots, μ_N $\in \mathcal{P}_1(\mathbb{R}^d)$

$$x = \begin{bmatrix} T \\ x_1 & \dots & x_m \\ \vdots & & \vdots \end{bmatrix}, \quad y = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix}$$

ריבועי \Rightarrow $x \in X$. זו דוגמת כלאוין

לראזרן ר- x . זו דוגמת כעוזה.

[$i \in \text{p1pnp} \cap \text{p1} - Z_i$, $\text{p1} - Z_i = \underline{\text{No}}$] (i የዚህ ማብራሪያ $j \rightarrow i$ አንቀጽ ተስተካክል) :

• If label \rightarrow , we find $f(x)$ for x in range of f : $X \rightarrow Y$.
 • If label \leftarrow , we find x for y in range of f : $X \rightarrow Y$.

• x ex se lifetime \rightarrow we wish to fit $f(x)$ to x_i, Y_i \leftarrow f function we want to find:
 have $y_i = f(x_i) + \epsilon_i$ where ϵ_i is noise. If we ignore the noise we will get "perfect fit" \star
 $\hat{f}(x) = f(x)$ (no noise) \leftarrow $f(x) = \hat{f}(x)$ \leftarrow no noise \leftarrow $\epsilon_i = 0$ \leftarrow $y_i = f(x_i)$

$$H_{lin} = \left\{ (x_1, \dots, x_d) \mapsto w_0 + \sum_{i=1}^d x_i w_i \mid w_0, w_1, \dots, w_d \in \mathbb{R} \right\}$$

(β_0 נקראת intercept) w_1, \dots, w_d מוגדרים כvariable ה- H ל- lin (ה- H ל- lin). ה- H ל- lin מוגדרת כפונקציית נגזרת של פונקציית פירסומת.

$$x = (1, x^1, \dots, x^d)^T \in \mathbb{R}^{d+1} \quad \text{and} \quad X = (x^1, \dots, x^d) \in \mathbb{R}^d \quad \text{and} \quad w = (w^0, w^1, \dots, w^d)^T \in \mathbb{R}^{d+1}$$

$$H_{\text{lin}} = \left\{ x \mapsto x^T w \mid w \in \mathbb{R}^{d+1} \right\} : P \rightarrow \mathbb{R}$$

$$X = \begin{bmatrix} \frac{1}{T} & \cdots & \frac{1}{T} \\ X_1 & \cdots & X_m \\ 1 & & 1 \end{bmatrix} \in \mathbb{R}_{(d+1) \times m} : p \in$$

(Sample ۱۰۰٪ درست است) $H_{lin} \Rightarrow f$ نکاتی را در مورد f بگوییم

func bool פונקציית יסוד, הפונקציה יפה : Realizable -> הנקודות ①

$w \in \mathbb{R}^{d+1}$ - $y_i = x_i^T w$: $\lambda N, p_N \{ (x_i, y_i) \}^m = S$: S מתקיימת נורמליזציה.

Wuk k3n5 i33j1 X^T w = y : pnpn i33 , n3f3 i33 j1 wuk k3n5

3. נסיעה מינימלית: $y = \mathbf{X}^T w$ ו- w מוגדר **realizable** אם קיימת w מינימלית.

(☺ נקודות פול)

የኢ.ፌ.ዲ.ሪ 3/1/21 ክፍና ማረጋገጫ *

גנרטיב לא-ריאלייזבָּל (Non-Realizable) → גנרטיב ריאלייזבָּל (Realizable) ②


כ' גנפ' ור' ממייה ר' פאל' ירא'ו, מא' מרג' ר' פאל' ירא'ו, מא' מרג' ר' פאל' ירא'ו.

$$\forall \psi_i \in \mathbb{R}^m, X = \begin{bmatrix} \leftarrow \psi_0 \rightarrow \\ \vdots \\ \leftarrow \psi_d \rightarrow \end{bmatrix}$$

$y \in \text{Im}(X^T)$ if, $\exists w \in \mathbb{R}^{d+1}$ such that $X^T w = y$ - \Rightarrow Realizable - נזקיה.

$y \notin \text{Im}(X^T)$ if, $\forall w \in \mathbb{R}^{d+1}$, $X^T w \neq y$ - \Rightarrow Non-Realizable - נזקיה.

$\text{Im}(X^T) = \text{Span}\{\psi_0, \dots, \psi_d\} \subseteq \mathbb{R}^m$: $\dim(\text{Im}(X^T)) = d+1$ $\leq m$



$\text{Im}(X^T) \subseteq \mathbb{R}^m$ if and only if the vectors ψ_0, \dots, ψ_d are linearly independent.

$f \in \mathcal{H}_{lin}$ if and only if f is a linear combination of ψ_0, \dots, ψ_d .

$y \in \text{Im}(X^T)$ if and only if $y = f(x)$ for some $x \in \mathbb{R}^{d+1}$ - \Rightarrow Realizable (1).

ψ_0, \dots, ψ_d are linearly independent if and only if $\text{Im}(X^T) = \mathbb{R}^m$.

$f \in \mathcal{H}_{lin}$ if and only if f is a linear combination of ψ_0, \dots, ψ_d .

$h_s \in \mathcal{H}_{lin}$ if and only if $h_s = \sum c_i \psi_i$.

$f \in \mathcal{H}_{lin}$ if and only if $f = h_s$.

$f \notin \mathcal{H}_{lin}$ if and only if $f \neq h_s$.

Loss h_s loss $L(y, h_s(x))$ loss $L(\cdot, \cdot)$

$L(y, h_s(x)) = |y - h_s(x)|$ Absolute Value Loss - L1 loss.

$L(y, h_s(x)) = (y - h_s(x))^2$ Squared Loss

הה sum squared error (SSE) $\sum (y_i - h_s(x_i))^2$ loss L .

$\sum_{i=1}^m L(y_i, h_s(x_i))$ loss L .

loss L loss h_s loss L .

$\sum_{i=1}^m (y_i - h_s(x_i))^2$ loss L .

הה sum squared error (SSE) $\sum (y_i - h_s(x_i))^2$ loss L .

$y_i - h_s(x_i)$ residual r_i loss L .

Residual sum of Squares (RSS) $\sum r_i^2$

(ERM) Empirical Risk minimization $\arg \min_w \text{RSS}(w)$ loss L loss L loss L

RSS -> פונקציית כפיפה, מינימום תחלה

$$\omega \mapsto \|y - X^T \omega\|$$

אם y לא בישר נאותי אז $\exists \omega$ שקיים $y = X^T \omega$. כלומר y ניתן לרשום כlinear combination של אונטיה x_i .

$$h_{\omega}(x) = x^T \omega : \text{function}, \omega = \arg \min \|y - X^T \omega\|$$

המינימום מושג על ידי $\hat{\omega}$

(1) נתקלה ב- non-realizable RSS => אין מינימום מושג.

(2) נתקלה ב- realizable RSS => הפונקציה f מוגדרת וינה 0, וזה מושג על ידי $\hat{\omega}$.

RSS => מינימום מושג? מינימום מושג מוגדר?

המינימום מושג אם קיימת ω שקיים $y = X^T \omega$.

RSS => מינימום מושג מוגדר על ידי minimizer-ה

$$\partial_{\omega} \text{RSS}(\omega) = -2 \sum (x_i)^j (y_i - x_i^T \omega) = 0 : j \in \{0, \dots, d\}$$

המינימום מושג מוגדר על ידי $\hat{\omega}$ שקיים $y = X^T \hat{\omega}$.

$$\nabla \text{RSS}(\omega) = -2X(y - X^T \omega) = 0$$

$\forall j \in \{0, \dots, d\}$ $\langle \psi_j, y - X^T \omega \rangle = 0 \Leftrightarrow Xy = XX^T \omega \Leftrightarrow X(y - X^T \omega) = 0$:

המינימום מושג מוגדר על ידי $\hat{\omega}$ שקיים $y = X^T \hat{\omega}$.

$\langle \psi_j, y - X^T \hat{\omega} \rangle = 0$: מינימום מושג מוגדר על ידי $\hat{\omega}$.


$y - X^T \hat{\omega} \perp \text{Im}(X^T)$: $\hat{\omega}$ מוגדר בספנסר $\text{Span}\{\psi_0, \dots, \psi_d\} = \text{Im}(X^T)^\perp$, $j \in \{0, \dots, d\}$

$\hat{\omega} = y - \hat{y} \in \text{Im}(X^T)^\perp$:

$\hat{y} = X^T \hat{\omega} \in \text{Im}(X^T)$:

$\text{Im}(X^T) \ni y \Rightarrow \hat{y} \in \text{Im}(X^T)$:

המינימום מושג מוגדר על ידי $\hat{\omega}$.



$$\|y\|^2 = \|\hat{y}\|^2 + \|\hat{y} - X^T \hat{\omega}\|^2$$

$\hat{\omega} = X^T \hat{y}$:

$$\dim(\ker(X^T)) = 0 \Leftrightarrow \text{Im}(X^T) \text{ מושג מוגדר} : \dim(X^T) = n$$

$$\hat{\omega} = (X^T)^{-1} X^T \hat{y} : \dim(X^T) = n, \dim(\ker(X^T)) = 0$$

$$(\hat{\omega} \text{ מושג מוגדר } (X^T)^{-1} X^T \hat{y} \text{ ורשות } (X^T)^{-1} \text{ מושג}) ! \text{ נזינס יפה}$$

$\left(\begin{array}{c} \text{הנורמל} \\ \text{הטיפוס} \\ \text{הטיפוס} \\ \text{הטיפוס} \end{array}\right)$ יתלו עליה נורמל וטיפוסים נורמלים. אם כך אז $y \in \text{Im}(X^T)$. $\text{Im}(X^T) = \{y_0, \dots, y_d\}$ ו- y מוגדר ב- $\text{Im}(X^T)$ כקונטראגראד \hat{y} ו- $\hat{y} \in \text{Im}(X^T)$ מסוים.

אם y מוגדר ב- $\text{Im}(X^T)$ אז y מוגדר ב- $\text{Im}(X^T)$ מסוים. X^T נורמלי (2).

Realizable \Rightarrow $\exists U \in \mathbb{R}^{(d+1) \times m}$, $V \in \mathbb{R}^{m \times n}$ כך ש- $y = U \cdot \Sigma \cdot V^T$.

($U \cdot \Sigma \cdot V^T$ מוגדר y לא נורמלי, non-Realizable).

① אם y מוגדר ב- $\text{Im}(X^T)$ אז $y = U \cdot \Sigma \cdot V^T$ ו- $U \cdot \Sigma \cdot V^T$ מוגדר ב- $\text{Im}(X^T)$.

למה?

פונקציית המינימיזציה מוגדרת:

$$x = u \cdot \Sigma \cdot v^T : \forall x \in \mathbb{R}_{(d+1) \times m} : \text{rank } x = 1 \quad \text{realizable}$$

$\Sigma \in \mathbb{R}_{(d+1) \times m}$, $U \in \mathbb{R}^{(d+1) \times (d+1)}$, $V \in \mathbb{R}^{m \times n}$

$$\sigma_1 \geq \dots \geq \sigma_{d+1} \geq 0 : \sum_{i=1}^{d+1} \sigma_i^2 = 1 \quad \text{realizable.}$$

ולפונקציית המינימיזציה מוגדרת:

(XX^T) מוגדר ב- $\text{Im}(X^T)$ ו- $x \in \text{Im}(X^T)$ (ו- x מוגדר ב- $\text{Im}(X^T)$).

ולפונקציית המינימיזציה מוגדרת $\|x\|_2$ (ו- x מוגדר ב- $\text{Im}(X^T)$).

$XX^T - x^T x = \sum_{i=1}^{d+1} \sigma_i^2 - 1$ (ולפונקציית המינימיזציה מוגדרת $\|x\|_2$).

($\forall i \in \{1, \dots, d+1\}$ מוגדר $\sigma_i \geq 0$ ו- $\sigma_i^2 = \sigma_i \cdot \sigma_i$).

$\sigma_{d+1} > 0 \Leftrightarrow \dim(\text{Ker}(X^T)) = 0$.

אם $\sigma_{d+1} = 0$ מוגדר x ב- $\text{Im}(X^T)$.

$$\sum_{i=1}^{d+1} \sigma_i^2 = \begin{cases} \frac{1}{\sigma_i} & \text{если } \sigma_i > 0 \\ 0 & \text{если } \sigma_i = 0 \end{cases} \quad \text{realizable}$$


$$w_s = U \Sigma^+ V^T y : \text{realizable}$$

$$w = (XX^T)^{-1} X y$$

רמזור w_s מוגדר ב- $\text{Im}(X^T)$ ו- w מוגדר ב- $\text{Im}(X^T)$.

$\|w\|_2 = \min \{ \|w\|_2 \mid X^T w = y \}$

המינימיזציה מוגדרת ב- $\text{Im}(X^T)$.



? מתי מתקיים תבנית הדרישה $\hat{y}_i = \sum_j w_j x_{ij} + b$?

(הנורמליזציה) non-Realizable - וה Realizable - ה נורמליזציה זרמים.

(הנורמליזציה) זרמים סטנדרטיים $\hat{y}_i = \sum_j w_j x_{ij}$ ו $\sum_j w_j = 1$.

זרם סטנדרטי: $w_i = \frac{w_i}{\|w\|_2}$, $b = \frac{b}{\|w\|_2}$.

אם $w_i = 0$ אז $\hat{y}_i = b$.

אם $w_i > 0$ אז $\hat{y}_i > b$.

אם $w_i < 0$ אז $\hat{y}_i < b$.

זרם סטנדרטי: $w_i = \frac{w_i}{\|w\|_2}$, $b = \frac{b}{\|w\|_2}$.

אם $w_i = 0$ אז $\hat{y}_i = b$.

אם $w_i > 0$ אז $\hat{y}_i > b$.

אם $w_i < 0$ אז $\hat{y}_i < b$.

? מתי מתקיים תבנית הדרישה $\hat{y}_i = \sum_j w_j x_{ij} + b$?

מתקיים אם $\sum_j w_j x_{ij} \geq b$ ו $\sum_j w_j = 1$.

(הנורמליזציה) מתקיים אם $\sum_j w_j x_{ij} \geq b$ ו $\sum_j w_j = 1$.

הנורמליזציה מתקיימת אם $\sum_j w_j x_{ij} \geq b$ ו $\sum_j w_j = 1$.

$$\left(\frac{1}{\sigma_i} - \sum_{j \neq i} w_j x_{ji} \right) \geq b \quad \text{אם ורק אם } \sum_{j \neq i} w_j x_{ji} \leq \frac{1}{\sigma_i} - b.$$

? מתי מתקיים תבנית הדרישה $\hat{y}_i = \sum_j w_j x_{ij} + b$?

מתקיים אם $\sum_j w_j x_{ij} \geq b$ ו $\sum_j w_j = 1$.

(! מתקיים אם $m < d+1$ ו $m \geq d+1$ ו $\sum_j w_j = 1$).

מתקיים אם $m \geq d+1$ ו $\sum_j w_j = 1$ ו $\sum_j w_j x_{ij} \geq b$.

אם $m < d+1$ ו $\sum_j w_j = 1$ ו $\sum_j w_j x_{ij} \geq b$.

- מתקיים במקרה חסר רuido: noiseless case - מתקיים במקרה חסר רuido:

מתקיים אם $\sum_j w_j x_{ij} \geq b$.

מתקיים אם $\sum_j w_j x_{ij} \geq b$.

$$\left\{ (x_i, f(x_i) + z_i) \right\}_{i=1}^m : \text{מתקיים אם } \sum_j w_j x_{ij} \geq b \text{ ו } z_i \sim N(0, \sigma^2).$$

ההשׁתְּרָה כִּי יֵלֶא ?

$\forall \beta \in \mathbb{R}^m$ ו $w \in \mathbb{R}^n$ ו $y \in \mathbb{R}^m$: $f \in H_{lin}$: Realizable - ה- קנהה (1)


לפניהם מתקיים $y_i = X^T w + z_i$: ו $z \in \mathbb{R}^m$

$z = (z^1, \dots, z^m)^T$: ו $z \in \mathbb{R}^m$ ו $z_i \in \mathbb{R}$

רמז: שטח כפוף ל $X^T w$ ו $y = X^T w + z$

רמז: $y = X^T w$ ו $y \in \text{Im}(X^T)$: ו $w \in \text{ker}(X^T)$

ERM : מינימיזציה של פונקציית האפסון ב- \mathbb{R}^n ו $w_0 := \min_w \|y - X^T w\|$



$\hat{y} \in \text{Im}(X^T)$ ו $y \in \mathbb{R}^m$ ו $y_i = x_i^T w + z_i$ ו $z_i \sim N(0, \sigma^2)$ ו $y_i \sim N(x_i^T w, \sigma^2)$

ו $y_i \sim N(x_i^T w, \sigma^2)$ ו $y_i \sim N(x_i^T w, \sigma^2)$

* נסחה זה ריבוי מ- y על $x_i^T w$

(Maximum Likelihood) ERM : $\hat{w} = \arg \max_w P(y|w)$

$x_i \sim N(\mu, \sigma^2)$ ו $y_i \sim N(x_i^T w, \sigma^2)$

$$P(y|w) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i^T w - y_i)^2}{2\sigma^2}\right)$$

$\hat{w} = \arg \max_w P(y|w)$

$\hat{w} = \arg \max_w \log P(y|w)$

$\hat{w} = \arg \max_w \log L(w|y)$

$L(w|y) = \prod_{i=1}^m \frac{1}{(2\pi\sigma^2)^{m/2}} \exp\left(-\frac{(x_i^T w - y_i)^2}{2\sigma^2}\right)$

$\hat{w} = \arg \max_w \log L(w|y)$

$$\hat{w} = \arg \min_w \sum_{i=1}^m (x_i^T w - y_i)^2$$

ה- קנהה מינימיזציה
מינימיזציה של פונקציית האפסון

ב- \mathbb{R}^n מינימיזציה

ליניאריזציה ופיטינג פולינומי - Polynomial fitting

$\forall i \in [m]: \{y_1, \dots, y_m\} \subseteq \mathbb{R}$ \wedge $a_1, \dots, a_m \in \mathbb{R}$ \wedge $\sum_{j=1}^m a_j y_j = 0$ \Rightarrow $\exists j \in [m]: a_j = 0$

$p(a_i) = y_i : \{(a_i, y_i)\}$ ပေါ်ရမှု ဖြစ်သလို ပါ။

$$\mathcal{H}^d = \left\{ a \mapsto \sum_{k=0}^d w_k a^k \right\} : \text{ԱՀԱԵՐՆ ԱՐՄԱՆ}$$

$$x_i = (1, a_i, a_i^2, \dots, a_i^d) : \text{うるさい}$$

ו $w \in \mathbb{R}^{d+1}$: \Rightarrow פתרון של המשוואות $Ax = b$, ומכאן $x \in \text{ker } A^T$.
 נסמן $x = \begin{bmatrix} x_1 & \dots & x_m \\ 1 & \dots & 1 \end{bmatrix}^T \in \mathbb{R}_{(d+1) \times m}$:

באנט. נ. ב פולירוק (פּוֹלִירָק) בג'רין (גְּרַין) נמלטו מארץ ישראל לארץ מצריה, ומשם צעירים.

$i \in [30]: y_i = p(a_i), x_i = (1, a_i^1, \dots, a_i^d)$: training set \rightarrow P6

• מילויים של מילים במשפטים נאמרים כמפורט לעיל

רְגִזּוֹן מִזְמָרֶת וְעַמְקָמָה כְּנֵסֶת הַבָּיִת - bias (ג'ז')

• IgP bias \rightarrow

training set $\rightarrow z_1, \dots, z_{20} \stackrel{\text{iid}}{\sim} N(0, 4)$: unlabeled $\{z_i\}$

$$\{i \in \{0\} : (y_i = p(a_i) + z_i, \chi_i = (1, a_i^1, \dots, a_i^d)) \in S \} \subseteq \mathbb{N}$$

לעומת שיטות ה-MLP, שיטות רקורסיביות מוגדרות באמצעות סדרה של אינטגרציות רקורסיביות על מנת לearn את היחסים בין ה- x_i ו- y_i .

הוּא לְמַעַן גָּמְלָא וְלִזְמָנָה (בְּגַעֲגָעָה) זֶה גַּם־כֵּן (בְּגַעֲגָעָה).

ஏவையில் எப்படி மத்திய வருமானம் (prediction rule) கொண்டு

הוּא - מִי יְמִינֵךְ ? תְּלַבֵּשׂ תְּלַבֵּשׂ ? תְּלַבֵּשׂ תְּלַבֵּשׂ ?

הנ' פון זונטן (F. von Sonnenburg) מילא תפקיד חשוב בפיתוח תורת ה- H^d .

w ו- c גוררים. $y_i = x_i^T w + z_i$: מינימיזציה של הerroר.

• \hat{y} מוגדר $\text{Im}(X^T)$ והוא מושתת על מינימיזציה של הerroר.

• מכאן, סכום כל שורות x_i מוגדר כהו ניטור ב- $\text{Im}(X^T)$.

(במקרה הכללי, מינימיזציה של הerroר).

לפנינו, מינימיזציה של הerroר נזקפת כטביעה של \hat{y} .

הטענה היא "הerroר" אל תזקוף רצויים כ- \hat{y} .

הוכחה של הטענה:

הוכיחו, $\hat{y} = \text{Im}(X^T) - e$ (ב- e מינימיזציה).

זהו, וקטור הניטור הראשון כטביעה נזקפת.

$d+1 = m$ ו- m מינימיזציה כטביעה נזקפת.

• ($m > d+1$ פ.כ. מינימיזציה נזקפת).

• $\text{Im}(X^T)$ מינימיזציה נזקפת, $\text{Im}(X^T) = \text{Im}(X^T)^T$ (ב- X^T מינימיזציה נזקפת).

Variance - bias Tradeoff \rightarrow פ.כ. מינימיזציה נזקפת.

• סביר מינימיזציה נזקפת קיימת רק כטביעה נזקפת, וזה מינימיזציה נזקפת.

(bias נזקפת - כלומר מינימיזציה נזקפת מינימיזציה נזקפת).

אילו מינימיזציה נזקפת מינימיזציה נזקפת?

פ.כ. מינימיזציה נזקפת.

• סביר מינימיזציה נזקפת מינימיזציה נזקפת, כלומר מינימיזציה נזקפת.

פ.כ. מינימיזציה נזקפת.

... $d+1$ מינימיזציה נזקפת.

... m מינימיזציה נזקפת.