

715180 -

4 7/377

: מילוי, הגדלתו ותפקידו
 מושג אחד מ- $X = \mathbb{R}^d$ פונקציית domain Set X ו-
 הגדלתו מושג γ , פונקציית label Set γ , (ולא מילוי)
 ($\gamma = \{0, 1\}$ במקרה של ביניים או $\gamma = \{1, 2, \dots, n\}$ במקרה של מינימום n)
היפואנומיה $h: X \rightarrow \gamma$ prediction rule ?

training set $S = \{(x_i, y_i)\}_{i=1}^m$ (훈련 세트)

learner, prediction rule $h: X \rightarrow Y$ 의사

then $A : (X \times Y)^m \rightarrow (X \rightarrow Y) : (\Delta)$ learner , γ_{NIB}

בצ'ארלי פון וונסן, מלחין רוק ובלוז אמריקאי, ידוע בעיקר בזכות הלהיטים "Born to Run" ו-"Jungle Boogie".

הנתקה מארץ ישראל

? $\exists_{\text{JN}} \forall_{\text{M}_j} \exists_{\text{C}} \forall_{\text{N}_j} \forall_{\text{M}_j} \exists_{\text{N}}$

? jIN.kf. הַיְלָדִים כֵּן, וְיַעֲשֶׂה לְךָ יְהוָה.

3. זנינית כלא יפהן מילוטי, ו- 33.0 מילוטי ב- מ- מילוטי?

וְלֹא כִּי תַּחֲזִק אֶת-בָּנָה וְלֹא תַּעֲמִיד אֶת-בָּנָה וְלֹא תַּשְׁלִיכֵךְ בְּבָנָה

• batch supervised learning (e.g., NN, LR)

Data-generation Model

לפיו לא ניתן למסור ערך כלשהו.

: e.g. $X \in D$ algorithm and : Simple data generation model ①

$$x_i \stackrel{iid}{\sim} D \Leftrightarrow \begin{bmatrix} D \text{ es Ma\ddot{z}j } x_i \text{ b} \\ \text{Ma\ddot{z}j } x_i \text{ b} \end{bmatrix}$$

$f(x) = y$ 這不是 true underlying rule f (真正的規則)

. $x_i \stackrel{iid}{\sim} D$ ו $s = (x_i, f(x_i))_{i=1}^m$ (3)
 $x \stackrel{iid}{\sim} D$ (ר' $x \in X$ (test sample) ו s ב (4)

: בוגר בינה מלאכותית
 וקטור נתונים x_i ו $y_i = f(x_i)$: מטרית f מוגדרת ו $y_i = f(x_i) + z_i$: פונקציית רuido ו

: בוגר בינה מלאכותית
 $x_i \stackrel{iid}{\sim} D$ (PAC בינה מלאכותית) . $y = f(x)$: מטרית f ו $y_i = f(x_i) + z_i$ ו

: בוגר בינה מלאכותית ו $L_{D,f}(h) = \underset{x \sim D}{\text{def}} P[h(x) \neq f(x)] \stackrel{\text{def}}{=} D(\{x \in X | h(x) \neq f(x)\})$

misclassification error risk

. מוגדרת f, D ו $L_{D,f}$ *

ו $L_{D,f}(h)$ מוגדרת כפונקציית רisco ו $L_{D,f}(h)$ מוגדרת כפונקציית risk ו

: המקרה
 S lopne A supervised batch dataset מוגדר D ו $(X \times Y)^m \ni S = (x_i, y_i)_{i=1}^m$ ו $\forall i: x_i \stackrel{iid}{\sim} D$

ו $\forall i: y_i = f(x_i)$ ו $f: X \rightarrow Y$ מוגדרת (training set)

ו $\forall i: y_i = f(x_i)$ ו $f: X \rightarrow Y$ מוגדרת (training set)

ו $\forall i: y_i = f(x_i)$ ו $f: X \rightarrow Y$ מוגדרת (training set)

. $L_{D,f}(h)$: מוגדרת כפונקציית risk, $h: X \rightarrow Y$ מוגדרת על D ו

. D, f ו A מוגדרות. A - אוסף של x 'ים, f מוגדרת על A , $f(x) = y$ ו $y \in Y$ ו

: אלגוריתם הדרישה - מוגדרת כפונקציית risk, מוגדרת על A , $R(h) = L_{A,f}(h)$ ו

→ P/N & Sample complexity -! PAC-learnability .1

$H \subset \gamma^X$ ו-VC-dimension

ԴԱՎՈԴԻ ԱՆԴԻ ԲԼՇ ՊԱՀ-ԱՅՆԸ ԽԵՎԱՆ ԱՐԺՈՒՆ

הוכחה נסמן $\tilde{m}_H : (0,1)^{\mathbb{N}} \rightarrow \mathbb{N}$

پیوستی χ در D نیز باشد اگر $\varepsilon, \delta \in (0, 1)$ باشد

ר) $\exists h^* \in H$ ו- $\forall x \in D$ $f(x) = h^*(x)$

If $A \in \text{PBN rel} - L_{D,f}(h^*) = 0$ - e

$D \sim N(\mu, \sigma^2)$ iid $\tilde{m}_H(\varepsilon, \delta) \rightarrow \infty$

$A(\vec{s}) = h_{\vec{s}}$ הינה פונקציית פולינומית, כלומר $\sum a_i s_i^i$

תְּנַשֵּׁא בָּנָה וְנִשְׁאָה אֲלֹהִים כְּבָנָה : וְנִשְׁאָה

$L_{\theta,f}(h_S) \leq \varepsilon$: פירוט (נקוות)

Sample complexity \rightarrow alc \geq_3 PAC-ability \Rightarrow visualizing neural networks

בנין מילים (בנין מילים) (בנין מילים)

$$m_H : (0,1)^2 \rightarrow \mathbb{N} : (x,y) \mapsto H(x,y)$$

7.3) . \mathcal{H}^{\pm} $\text{կամ, այսպիսի պյուն } \mathcal{H} \subset \{\pm 1\}^X$ է։

የዚህ, $H_C = \{h_c | h \in H\}$: ነገሮች, C -ኛ H ላይ በዚህንና የተደረገ ዘርፍ H_C

: H le VC-dimension \rightarrow $w_C(2,3)$. $w_C = h|_C : C \rightarrow Y$

$$\infty \geq VCdim(H) := \max \{ |C| \mid C \subset X \wedge |H_C| = 2^{|C|} \}$$

(ללאר ה-18 נויר. ו-19 נויר. ב-19 נויר. ו-20 נויר.)

? Pen as and

וילסן ה-ה' ג' צייר תנ"ל אבנימלך י"ג ינואר PAC - 13.1.5

The fundamental Theory . p3, p 123n will , n3, N50 will p18

רַבָּה: מִתְּבָרֵךְ כָּל הַבָּשָׂר וְכָל הַגָּבֵר וְכָל הַנֶּזֶר

$\infty > \text{VC dim } (\mathcal{H}) \iff \text{PAC} - \text{learnable} \hookrightarrow \mathcal{H}$ רשות רשות רשות *

וְיִדְעָה הַנֶּגֶז בְּנֵי יִשְׂרָאֵל כִּי־בְּנֵי יִשְׂרָאֵל וְכַא־בְּנֵי נָחוֹר

$$m_H(\varepsilon, \delta) \sim \left(Vc \dim(H) + \log\left(\frac{1}{\delta}\right) \right) / \varepsilon$$

הנ' f מושג כפונקציית אינטגרל (DEFINITION) על שטח E ב- \mathbb{R}^n .
 מושג אינטגרל סטטיסטי (STATISTICAL INTEGRAL) על שטח E ב- \mathbb{R}^n מוגדר כפונקציית אינטגרל סטטיסטי (STATISTICAL INTEGRAL).

פונקציית אינטגרל

פונקציית אינטגרל (DEFINITION) מושגת כפונקציית אינטגרל סטטיסטי (STATISTICAL INTEGRAL) על שטח E ב- \mathbb{R}^n מוגדרת כפונקציית אינטגרל סטטיסטי (STATISTICAL INTEGRAL) על שטח E ב- \mathbb{R}^n .

- f מושג כפונקציית אינטגרל סטטיסטי (STATISTICAL INTEGRAL) על שטח E ב- \mathbb{R}^n .
- f מושג כפונקציית אינטגרל סטטיסטי (STATISTICAL INTEGRAL) על שטח E ב- \mathbb{R}^n .
- f מושג כפונקציית אינטגרל סטטיסטי (STATISTICAL INTEGRAL) על שטח E ב- \mathbb{R}^n .

לפניהם מושג כפונקציית אינטגרל סטטיסטי (STATISTICAL INTEGRAL) על שטח E ב- \mathbb{R}^n .

לפניהם מושג כפונקציית אינטגרל סטטיסטי (STATISTICAL INTEGRAL) על שטח E ב- \mathbb{R}^n .

Probably, Approximately, Correct (PAC)

Like & Key

לפניהם מושג כפונקציית אינטגרל סטטיסטי (STATISTICAL INTEGRAL) על שטח E ב- \mathbb{R}^n .

לפניהם מושג כפונקציית אינטגרל סטטיסטי (STATISTICAL INTEGRAL) על שטח E ב- \mathbb{R}^n .

: לעכץ

לעכץ, מתקבז נעלם כל אחד. $\gamma > 0$ גודלו, $X = \{x_1, x_2\}$
הנ' $f_0 + \gamma x_1 f_1 + \gamma x_2 f_2$

$D(\{x_1\}) = 1 - \gamma$, $D(\{x_2\}) = \gamma$: מתקבז D ומכוח גודלו של
. (\star) $f(x_1) = f(x_2) = -1$: מתקבז f !

הנ' x_2 לא נעלם בנ' γ , γ^m מתקבז f .
 $h_S(x_1) = +1$, מתקבז f ? $h_S(x_2)$

$L_{D,f}(h) = 1 - \gamma : D(x_1), 1 - \gamma$ מתקבז f \Rightarrow מתקבז h , (\star) מתקבז

טב שורש, מתקבז loss-ו \Rightarrow מתקבז f (ג'רין loss-ו \Rightarrow מתקבז f)

x_1 מתקבז x_2 מתקבז, מתקבז f ? מתקבז?

D מתקבז f מתקבז f , מתקבז f מתקבז f , מתקבז f מתקבז f . איזה מתקבז?



. לעכץ 4

loss מתקבז מתקבז מתקבז, A מתקבז מתקבז מתקבז.

מתקבז, ($1 - \epsilon \leq \delta > 0$ ->) מתקבז מתקבז מתקבז מתקבז

confidence מתקבז δ -> probably correct learner מתקבז A ->

loss \rightarrow h_f (h_f מתקבז מתקבז מתקבז מתקבז)

. מתקבז מתקבז מתקבז מתקבז מתקבז מתקבז מתקבז מתקבז

loss = 0 מתקבז ($1 - \delta$ מתקבז מתקבז A מתקבז מתקבז מתקבז).

: מתקבז loss = 0 . לעכץ ? גודלו של מתקבז מתקבז מתקבז

מתקבז מתקבז מתקבז מתקבז מתקבז מתקבז מתקבז מתקבז

$x \in X$ -> מתקבז מתקבז מתקבז מתקבז מתקבז מתקבז מתקבז מתקבז

מתקבז מתקבז מתקבז מתקבז מתקבז מתקבז מתקבז מתקבז

. מתקבז מתקבז מתקבז מתקבז מתקבז מתקבז מתקבז מתקבז

: לעכץ

. $x \notin S$ 'ב' A מתקבז מתקבז מתקבז מתקבז מתקבז מתקבז

$D(\{x_1\}) = 1 - \gamma$, $D(\{x_2\}) = \gamma$ מתקבז מתקבז + מתקבז מתקבז מתקבז מתקבז

. $x_2 \notin S$: $(1 - \gamma)^m$ מתקבז מתקבז \Rightarrow $f(x_1) = f(x_2) = -1$, גודלו מתקבז מתקבז מתקבז

לעכץ 3

then the pair A has μ_{AC} , & confidence of : α
 D_f of δ , $1-\delta$ interval is $= L_{D_f}(\delta)$ of δ

- approximately correct ($\text{LRP} \approx 0$) : with small back error
- when ϵ is small: $\mathbb{E}[\ell_{D,f}(h)] \leq \epsilon$ if h is small
- if $\epsilon = 0$ then A is approximately correct learner
- accuracy \rightarrow large $\mathbb{E}[\ell]$ small $\mathbb{E}[\text{back error}]$

probably approximately correct: A - δ exp. δ w. ϵ b
 \cdot confidence δ -1 accuracy ϵ P

$$\text{PLC } (\varepsilon, \delta) \text{ PAC-13NS } A: S \rightarrow h_S : \underline{\text{GNN}} \text{ para } \\ P_{D^m} \left\{ S \in (\chi \times \gamma)^m \mid L_{D,f}(h_S) \leq \varepsilon \right\} > 1 - \delta : D, f \text{ b.s} \\ \left[\left((x_i, y_i) \overset{m}{\underset{i=1}{\overbrace{\cdots}}} \right)_{i \in S} \right] \\ x_i \overset{i.i.d}{\sim} D - \delta$$

• פונקציית פירס, PAC הינה פונקציה ממשית מ \mathbb{R}^m ל \mathbb{R}
 • f היא פונקציית פירס אם ורק אם $f(x) = \max_{y \in S} g(y)$ עבור כל x ופונקציית פירס היא
 • A_m היא פונקציית פירס אם ורק אם $f(x) = \max_{y \in S} g(y)$ עבור כל x ופונקציית פירס היא
 • $(m \geq p, q \in \mathbb{N})$ A_m פונקציית פירס אם ורק אם

$$A_m: (\mathbb{X} \times \mathbb{Y})^m \rightarrow \mathbb{Y}^*$$

pre, confidence: 870, accuracy: 870 (pp)

Random payoff of 80% 3rd plan

$\beta N f_1$, (sample size) m \rightarrow f_1 (normal) \rightarrow y^*
 $\rightarrow p, f_2$, $A, m - e$ (no). $A: (X \times Y)^m \rightarrow Y^*$
 $\varepsilon, \delta \rightarrow p, f_2$

۱۳۷۶

לפוזינ איג'סילס צויר, Am NC fsi' גורן.

$A, m, \varepsilon, \delta \rightarrow$ תיילן דעטסוקל צניב

प्रति, $D - N$ iid वर्गीय में प्रियः : रेन्न प्रैन्स
 \hat{P}^N के लिए वर्णन करें।

$$h_S = A(S) \rightarrow^f S(n)$$

$L_{D,f}(h_S) : \text{payoff} \rightarrow \mathbb{R}^{3|N|}$

לכ דעוני, ר' מגדון (יענין גודל מילך רג) פונט אל גדר
 $\{S^n D^m \mid L_{D,f}(hs) \leq \varepsilon\}$: נ"ז (ו' פ' זרנוק פ' נסזנץ ז' פ' גודל מילך רג)

3) $\sigma = (\text{PAC} \cdot \beta_N)/(\alpha A \cdot \gamma_N)$ $1 - \delta < \sigma < \infty$ מתקיים אם $\alpha A \cdot \gamma_N > \beta_N$.

הנתקה מ-m ? m הינה נתקה מ-N.

PAC- β NF kile A k³NF byle 32 f³34 p³on 1.36

የጊዜና ወጥቶ ችልርንግም. tradeoff የ. ስር

... ∞ \cap $\{x \in \mathbb{R}^n : f(x) < \infty\}$ $\neq \emptyset$

מ נויה (3) מילא כהן ב-ר, ד.ל. מילא מילא ? ר

more accurate - I'm more confident in my knowledge. (b) If

6. גיבוריך של הינה נספה ונעה (4 רדוקצייה). $|X| = 2 - \int_{\Omega} u$

١٤٢

የሸጋዎች ነውም, $g(x)$ ሲሆን $x \notin S$ በሸጋዎች ነው, ይህንን ለማስረጃ ለመ

D, $|C| > 2m$: $\exists x \in \mathbb{R}^n$ ככזה ש $f(x) = -g(x)$ $\therefore C$ מוגדרת היטב.

. C f D , C

: $\text{P}^n \mathcal{P} M$. $\text{Supp}(S) \subset G$: $\text{P} M n_j$. S Py3_{n_j} : $\text{P} M n_j \mathcal{P} M_n$

- $\mu_{\text{PN}} \in \mathcal{C}_m$ if $\exists n \in \mathbb{N}$ - μ_{PN} is m -summable, $|\text{Supp}(\mu)| \leq m$

$$\text{If } \lambda > 0, \text{ then } P(\{x \in X \setminus \text{Supp}(\beta)\}) \geq 1/2$$

$$\frac{1}{g} \text{ and } f(\omega) \text{ of } S_N \text{ are like } p$$

$$h_S = A(S)$$

پ ۴ $g(x)$ یعنی دسته‌بندی ها : loss \rightarrow هدایت

186.1 , የሚገኘ ነው ሲሆን በዚህ ደንብ የሚከተሉት የሚመለከት ስርዓት የሚያስፈልግ ይችላል

$L_{D,f}(h_S) \geq \frac{1}{2}$ pf. $f(x) = -g(x)$ wifje $G, f_0, \dots, g_0, \dots$

loss $\geq \frac{1}{2} \rightarrow$ minf \geq minf - pos, use A, B, C \leftarrow

ପିଲ୍ଟର କୋମାନ୍ କରିବାକୁ ପାଇଁ ଏହାକୁ ବିଶ୍ଵାସ କରିବାକୁ ପାଇଁ ଏହାକୁ ବିଶ୍ଵାସ କରିବାକୁ ପାଇଁ

• $|X| = N$ ($\forall i \in \{1, 2, \dots, N\}$)

የሸጋ ተከራካሪ ነው ይህንን ማስረጃ የሚያሳይድ ይችላል?

וְנִזְרָקֶת יְמִינֵךְ וְנִזְרָקֶת יְמִינֵךְ וְנִזְרָקֶת יְמִינֵךְ

23.15 [21] KF-13N 1132 f-f 1.200127 1107 en p/c ps

$P_3 \beta_{PN} f_{3,N}(\omega) = P_3 P_N N(0) I_C \frac{1}{I_C} \frac{\partial^2 \phi}{\partial \omega^2} \Leftrightarrow PAC - \beta_{N5}$

• A $\beta N \rightarrow p + n$ reaction is exothermic. $E < \frac{1}{2} \Delta E_{\text{kin}}$

χ if $D(x)$ never np in $\beta_1 \cap$ training set $\tilde{s} - 1$

ר' נ' If $f \in \text{Homeo}^+(P)$ so $f: X \rightarrow Y$ אוניברסלי יי'ה

$D \sim N$ iid pýzje m. Bior n training sample ->

$$h_S = A(S) - r \quad L_{D,f}(h_S) \geq \varepsilon \quad p, p_M$$

רְבָבָה כִּוְנָה וּבְגַדְלָה גַּם נִמְצָא בְּגַדְלָה וְבְגַדְלָה יְלִיכְמָה בְּגַדְלָה.

מג'ס f DJNN H^{CY^} NSNS פונקציית

: P, 7 PN 2-2 WPN

ממד גנריות הינה מודולר: realizable (1)

$\therefore \text{Let } h^* \in H - \mathcal{F} \text{ and } D\text{-almost surely } \text{ref}^*(\omega) \text{ in } \mu$

$$\exists h^* \in H \text{ s.t. } D(\{f(x) = h^*(x)\}) = 1 \rightarrow_{NIS}$$

$$A(S) = hs : (X \times Y)^m \rightarrow H : \text{using } 3 \text{ NIS} \rightarrow$$

: מתקובל עליה נסיבות

? PAC - $\exists N \forall \delta \exists n \forall m \forall f \in H$ " $N \in \mathbb{N}$ ו- f פונקציית m מ- $X \times Y$ ל- H "

? PAC - $\exists N \forall \delta \exists n \forall m \forall f \in H$ " $N \in \mathbb{N}$ ו- f פונקציית m מ- $X \times Y$ ל- H "

ונגזרות מ' ϵ, δ מ' S . f " $N \in \mathbb{N}$ ו- f פונקציית m מ- $X \times Y$ ל- H "

ונגזרות מ' ϵ, δ מ' S , (ϵ, δ) PAC מ' m, A

$\exists N \forall \delta \exists n \forall m \forall f \in H$ " $N \in \mathbb{N}$ ו- f פונקציית m מ- $X \times Y$ ל- H "

? PAC - $\exists N \forall \delta \exists n \forall m \forall f \in H$ " $N \in \mathbb{N}$ ו- f פונקציית m מ- $X \times Y$ ל- H "

? ϵ, δ מ' S ו- f פונקציית m מ- $X \times Y$ ל- H "

מ' N מ' S ?

A מ' S מ' ϵ, δ מ' H " $N \in \mathbb{N}$ ו- f פונקציית m מ- $X \times Y$ ל- H "

? הנחתה N ? $N \in \mathbb{N}$ ו- f פונקציית m מ- $X \times Y$ ל- H "

ונגזרות מ' ϵ, δ מ' S ו- f פונקציית m מ- $X \times Y$ ל- H "

? הנחתה N ? $N \in \mathbb{N}$ ו- f פונקציית m מ- $X \times Y$ ל- H "

? $N \in \mathbb{N}$ ו- f פונקציית m מ- $X \times Y$ ל- H "

: פונקציית m מ- $X \times Y$ ל- H

$H \subset Y^X$ מ- X , confidence - $\delta > 0$, accuracy - $\epsilon > 0$ מ- H

. random payoff P_f מ- H מ- S מ- $X \times Y$ ל- H

מ- S מ- H מ- $X \times Y$ ל- H

. כחישו רכבי m מ- $X \times Y$ ל- H מ- S מ- H

. כחישו רכבי m מ- $X \times Y$ ל- H מ- S מ- H מ- S מ- H

לעדי f מ- S מ- H מ- $X \times Y$ ל- H

. ($H \subset Y^X$ מ- X , $\delta > 0$ מ- H) almost-surely

. f מ- S מ- H מ- $X \times Y$ ל- H מ- S מ- H

. $A(S) = hs$

. ($S \subset H$ מ- $X \times Y$ ל- H) payoff \rightarrow מ- S מ- H

(P_f מ- S מ- H) $P_f \in \mathbb{R}$ מ- S מ- H

PAC - $\exists N \forall \delta \exists A \forall \epsilon \forall S \forall f \in H$ מ- S מ- H מ- S מ- H

. $P > 1 - \delta$ מ- S מ- H

ולכ . $\sin \mu_j$ lf $H = y^x - 1$ $\infty = |X|$ reker yik
 \rightarrow PAC - $\sin \mu_j$ $|X| = \infty$ \rightarrow PAC "גוגי מודד" H pf

15.07.2023 Apfelnikov, 1c, 13f). $\gamma = \{0, 1\}$, $X = \mathbb{R}$: $|x| \geq 1$

H_{th} = $\{x \mapsto h_\theta(x) \mid \theta \in \mathbb{R} \cup \pm\infty\}$: Threshold functions

$$h_\theta(x) = \begin{cases} x \leq \theta: & 0 \\ x > \theta: & 1 \end{cases} \quad (h_{-\infty}(x) \equiv 1, h_\infty(x) \equiv 0)$$

* הו ה- ϵ -realizable: $\exists \text{ רד}$ δ ה- ϵ -realizable \forall x \exists y $d(x,y) < \delta$

לפניהם הינה מושג של רשות מינהלית (R.M) שפועלת כגוף אחד ומייצגת את כל אחד מבעלי הרכבת.

$\Theta_{alg} = \max_{\Theta} (x_i) : \text{ויש } \Theta \text{ ו } x_i \text{ נור}, \text{training Samples } x_i \text{ ו } y_i$
 $\Theta_{alg} = \infty \text{ נור}, \text{�ען } S \supset \text{PLIC}, h_{\Theta_{alg}} \in H_{th} \text{ נור}$
 $\Theta_{alg} = -\infty \text{ נור } 0 \text{ נור } S \supset \text{PLIC}$
 $\text{ולפנוי } S \text{ ש } m > \frac{1}{\epsilon} \log(\frac{1}{\delta}) \text{PLIC} . \exists \delta > 0 \text{ נור} - \text{גאון}$
 $\text{לפנוי } \Theta_{alg} \in H_{th} \text{ ו } \Theta_{alg} \in H_{th}, R_f \in D$
 $\epsilon \text{ נור } S \text{ ב } L_{D,f}(h_{\Theta_{alg}}) : \text{loss} \rightarrow (m=|\mathcal{S}|, S \stackrel{iid}{\sim} D \text{ נור})$

$f_0 \in H_{th}$ so for all R if P wins \liminf .

የየንና ስር ተ ንዑስ የቦናስ ማር . ተደግኝ ተ ተ ማኑ ስር *

- D -s INN P2 1-! D -s INN P2 0 ειν μι

$X \leq \Theta_{alg}$ if and only if $\Theta_{alg} < \theta$ which means \leftarrow

$$\left(\begin{array}{c} \text{לפניהם נסח} \\ \text{בכדי ש} \end{array} \right) \cdot \theta_{\text{alg}} < x < \theta \quad \text{ונפ' } \theta > 0.1, \quad x > \theta \quad \text{ונפ'}$$

$$\text{পৰি } D(\{x \mid x \in (\Theta_{\text{alg}}, \Theta)\}) \times \varepsilon \text{ sic : } D(\{x \mid -\alpha < x < \Theta\}) < \varepsilon \text{ (1)}$$

⑪ . $m \parallel c S \rightarrow N \cap \partial N$ կը : 1 դուրս է $\rightarrow L_{p,h_0}(h_0|_{\partial N})$

$$x \in [\theta, \Theta] \text{ if and only if } (x, u) \in \mathbb{R}^2 \text{ for some } u \in \{1, 2, \dots, n\}$$

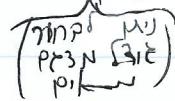
(1-\varepsilon)^m \text{ (2) } \text{לענין ש } k \text{ מוגדר כ } \lceil \frac{1}{\varepsilon} \rceil \text{ ו } \varepsilon \geq \delta \text{ נסsat } \Rightarrow \exists c

$$m \geq \frac{1}{\varepsilon} \log\left(\frac{1}{\delta}\right) \Leftrightarrow e^{-\varepsilon m} < \delta : \text{because } 1-\delta \leq e^{-\varepsilon} : \text{PAC bound}$$

. PAC- β nd A $\Leftrightarrow \varepsilon \geq \text{prob of error } 1-\delta \leq \text{prob of error}$

Since μ is not PAC- β nd it's not learnable with probability ε .

PAC-learnable Hypothesis classes are PAC- β nd.



? PAC- β nd or not

if H is PAC- β nd then ε is called a margin (1)

and if H is not PAC- β nd then ε is called a margin (not PAC)

if $(loss \rightarrow \text{NC class})$ then ε is called a margin : (with rule)

: ERM \rightarrow ε \Leftarrow training set \rightarrow

empirical risk \rightarrow s.t., training set $\tilde{S} = \{(x_i, y_i)\}_{i=1}^m$

$$L_S(h) = \frac{1}{m} |\{i | h(x_i) \neq y_i\}| : \forall h \in H \text{ margin } \varepsilon \text{ of } h$$

: since empirical risk \rightarrow NC class (if h has margin ε)

. (ERM) ERM- β nd \Leftrightarrow ε is valid. AERM : $S \mapsto \arg \min_{h \in H} \{L_S(h)\}$

. $\arg \min$ prop of $L_S(h)$, ε is margin of h , $L_S(h) \geq 0$: if $\varepsilon \neq 0$ *

: prop of $L_S(h) = 0$ \Leftrightarrow $\forall i | h(x_i) = y_i$, realizability \rightarrow margin, ε

$$L_S(h) = 0 \Leftrightarrow \forall i | h(x_i) = y_i, L_S(f) = 0$$

$h \in H$ such that ERM- β nd (realizability) \Rightarrow margin ε *

o consistent \Leftrightarrow $\exists h \in H$ $\forall i \in [m] | h(x_i) = y_i$ \forall

training sample \rightarrow ε is good if $\varepsilon \geq 0$

in the next β nd PAC- β nd \Leftrightarrow ε is margin of h \forall $i | h(x_i) \neq y_i$ \Leftrightarrow

$$\text{size } \log\left(\frac{|H|}{\delta}\right) \cdot \frac{1}{\varepsilon} \geq \text{prob of error } \varepsilon, \text{ ERM} \rightarrow$$

. $|H| < \infty$ \Rightarrow ε is margin $\forall i | h(x_i) \neq y_i$, sample space X \hookrightarrow \mathbb{R}^d : ε is margin $\forall i | h(x_i) \neq y_i$ \Leftrightarrow ε is margin $\forall i | h(x_i) \neq y_i$

. (S, m) \Rightarrow $1-\delta \leq \text{prob of error}$, $\varepsilon \geq L_{D,f}(\text{ERM}_H(S))$: prop of D, f

. (n, ε) \Rightarrow $m \geq \frac{\log(n/\delta)}{\varepsilon^2}$ \Leftrightarrow $n \geq \frac{\varepsilon^2 m}{\delta}$ \Leftrightarrow $\log(n/\delta) \leq \varepsilon^2 m$ *

$m(\varepsilon, \delta) \leq \frac{\log\left(\frac{1/\delta}{\varepsilon}\right)}{\varepsilon}$: Sic ε, δ alc m p/c $\Rightarrow \varepsilon, \delta, m$ (לפניהם)

$m(\varepsilon, \delta) \leq \frac{\log\left(\frac{1/\delta}{\varepsilon}\right)}{\varepsilon} = \frac{\log(1/\delta) + \log(1/\varepsilon)}{\varepsilon} = \frac{\log(1/\delta)}{\varepsilon} + \frac{\log(1/\varepsilon)}{\varepsilon}$

$\frac{\log(1/\delta)}{\varepsilon}$ נקראת $H - \ell$ (הערך של H מינימלי שקיים δ בו)

$\frac{\log(1/\varepsilon)}{\varepsilon}$ נקראת J_{NG} (הערך של J_{NG} מינימלי שקיים ε בו)

$$\varepsilon \leq \frac{\log\left(\frac{1+\delta}{\delta}\right)}{m} \quad : \text{SIC m, } \delta \text{ NC NPP PC} \\ \delta \leq \frac{1+\delta}{e^{m\varepsilon}} \quad : \text{SIC m, } \varepsilon \text{ NC NPP PC}$$

$$h_{a,b,c}(x) = \begin{cases} x \in [a,b] \vee x \geq c: 1 \\ x < a: 0 \end{cases} : \text{KvB} \quad \Rightarrow \quad \mathcal{H} = \{ h_{a,b,c} \mid a < b < c \in \mathbb{R} \}, x \in \mathbb{R}$$

: NIS

. Hth iku "Nis" apjan is sic

C if h (a is fun) sc (no) . then h: $x \rightarrow y$ -1 ccx in
 $\cdot x \in C$ if $h_C(x) = h(x)$ $\rightarrow h_C : C \rightarrow y$: \circ

ל-3NF גודל הקבוצה המינימלית שפירושה היא קבוצה שלם.

לעומת נציגי מדיניות חוץ

לפניהם נקבעו פונקציות. לאן מתייחסות הנקודות? $\{x_n\}$
 נסמן על ידי $\{x_n\}$ סט. א. $\{x_n\}$, $\{n\in \mathbb{N} : x_n > \frac{m}{k}\}$ אינטגרה
 $(g: X \rightarrow Y \text{ ב�ון } \mathbb{N})$ $g(x): S \rightarrow \{x_n\}$ כך $x \in X \Rightarrow g(x) \in \{x_n\}$
 $(h_S \in H \text{ ו- } p \models \forall k \exists j)$

- $g(x)$ מוגדרת כפונקציית אובייקטיב כפונקציית פונקציית P שפונה בפונקציית f , כלומר f מוגדרת כפונקציית P שפונה בפונקציית g . $x \in C$ אם ו רק אם $(\text{realizability} \rightarrow \text{המונח שפונה בפונקציית } g \text{ הוא } x) \wedge (x \in C \rightarrow \text{המונח שפונה בפונקציית } f \text{ הוא } g(x))$.

training sample points H in \mathbb{R}^n iff G_{ij} is s.t. $\{h_i^T h_j\}_{i,j \in H} = (C \rightarrow Y)$

א. ג. י. פ. 12 $\{h_c | h \in \mathcal{H}\} = (C \rightarrow \gamma)_{\text{MPNE}} \subset \text{א. ג. י. ב. 12}$ ↪
 (sample complexity) מתקיים מינימום פונקציונלי (i)
 'פ' נס'ן ה' $n \in \mathbb{N}$ בס' \propto גודל המ训' ב. 12 פ' (ii)

• C if H ו המונע H_C $\subseteq H$ $C = \{x_1, \dots, x_{|C|}\}$ לפניהם
 • \exists ג' $\in \mathcal{G}$, $y = \{\pm 1\}$ $\text{מ}'$ g , $\forall h \in H_C$ $(h_C = \{h(x_i) | x_i \in C\}) \supseteq \{y\}$
 פונקציית h $\in H$. $(h(x_1), \dots, h(x_{|C|})) \in \{\pm 1\}^{|C|}$ $\text{מ}'$ $h \in H$
 $|H_C| \leq g^{|C|}$ $\forall i \in C$, $\exists j \in |C|$ $i \neq j$
 H shatters C : $\exists \gamma \in \mathcal{G}$ $x \in C$ $\forall h \in H_C$ $h(x) = y^h$ properly
 המונע \exists $\gamma \in \mathcal{G}$ $\forall h \in H_C$ $h(x) = y^h$ properly

$$VC_{dim}(H) = \max \{ |C| \mid H \text{ shatters } C \}: \text{VC dimension of } H$$

ונספ' ג' שטף ג' ו' כ- 3NN רטף. 35

• ה' ג' נספ' ג' + 3NN כ' pp ו' ג'

• It is if $\text{נספ}' \leq 3NN \text{ כ' pp}$ & .9