

29/5/20 - 1

#7 水300

רזה כ- 90°C רצוף ורצעונייזיג.

וילא רצע אל גנובין כחיזוקין, ורוכין כי שולג כעכטיה
וילא רצע אל גנובין כחיזוקין, ורוכין כי שולג כעכטיה.

(ج) ملحوظات

בעודנו נזכיר את הנקודות שקבעו לנו את המרחב A ו- B .
בנוסף לכך, נזכיר את הנקודות x ו- y , שקבעו לנו את המרחב C .

לפיכך $\int_{\gamma} f(z) dz = \int_{\gamma} \frac{f(z)}{z-a} dz$ ו- $\int_{\gamma} \frac{1}{z-a} dz = 2\pi i$

$$A_o(s) = h_s := \arg \min_{h \in \mathcal{H}} F_s(h)$$

הTERM F_S fidelity term

: 2013 Pj3N55 '213

לעומת הדרישה מ- $F_3(h)$ נקבעו $\alpha = \beta = 0$.

• (Maximum likelihood, least squares, ERM algorithm)

אָל תַּנִּינְךָ, שְׁמֵךְ לְבָבֶךָ וְרִנְפָנְךָ אָל תַּשְׁמַנְנָה: אֲלֹתָךְ יְמִינְךָ וְכַעֲדָךְ

- $F_{\tilde{y}}(h)$: fidelity term - גודל פ�ינט הטעות ב猜测 הערך y

- $F_S(h)$ (ו PIN:J:N)alc ו אונ פל, פוג'נו גז'ר היל פר : SVM-ה

$\vec{p} = \{(x_i, y_i)\}_{i=1}^m \mid N \subset \mathbb{R}^{2N} \quad l(\cdot, \cdot) \text{ loss function} \quad \hat{p} \text{ is the output} : \text{ERM}$

$$L_p(h) = \frac{1}{m} \sum_{i=1}^m l(h(x_i), y_i) \quad : \text{empirical risk} \rightarrow (X \times Y)^m - n$$

ակն չ հետ ուն զի՞ն ԵՐՄ -> լորե շան բյու թնջ օք

$$F_S(h) = L_S(h) \text{ and } \operatorname{arg\min}_{h \in \mathcal{H}} F_S(h)$$

የሚገኘውን የሚከተሉት በቻ ነው፡፡ ይህንን ስምምነት ተረጋግጧል፡፡

(e) $P_{\text{adj}} > 0.300$ Projekten liegen weit außerhalb der Regressionskurve. Overfitting -> geringe Güte.

• ፳፻፲፭ ዓ.ም ከፃኑ ወጪ ተስፋል የሚከተሉትን የፌዴራል የፌዴራል የፌዴራል

? השאלה מתי מומלץ להשתמש בהמודל הפשוט ומתי המודל המורכב ?
rule of thumb: H vs S (1)

bias-variance tradeoff rule

rule of thumb: AoS vs F (2) ↪ rule of thumb

fidelity term (ככ שיער, ווכetta של ההשאלה) ↪ rule of thumb

: השאלה מתי מומלץ להשתמש בהמודל המורכב ומתי המודל פשוט ?
rule of thumb

- $\lambda \geq 0$ והשאלה $hs = \underset{h \in H}{\operatorname{argmin}} F_S(h)$ והשאלה

$$hs := \underset{h \in H}{\operatorname{argmin}} \{F_S(h) + \lambda R(h)\} : " \text{השאלה}" \quad A_\lambda : S \rightarrow hs$$

R: $H \rightarrow \mathbb{R}$: regularization term \rightarrow השאלה R real

מונע $R(h)$, $h \in H$ מהשאלה h להיות גודלה מוגבהת (בהשאלה h מוגבלת, והשאלה מוגבהת)

(rule of thumb)

Tradeoff rule

• השאלה מהשאלה $h - e$ בסיסי ?

• מינימיזציה $F_S(h)$ מהשאלה

• מינימיזציה $R(h)$ מהשאלה $h - e$ בסיסי ?

rule of thumb

: λ tradeoff \rightarrow ★

($F_S(h)$ מהשאלה מוגבלת והשאלה מוגבהת (בהשאלה $h - e$ בסיסי))

• מינימיזציה $R(h) - \frac{\lambda}{2} \|h\|^2$ מהשאלה מוגבהת $\rightarrow \lambda \rightarrow \infty$ •

• מינימיזציה $F_S(h) - \frac{\lambda}{2} \|h\|^2$ מהשאלה מוגבלת •

• מינימיזציה $\lambda \rightarrow \infty$ - tradeoff בין λ - $\lambda \in (0, \infty)$ •

• מינימיזציה $\lambda \rightarrow 0$ - $h \rightarrow e$ מהשאלה מוגבלת •

$\lambda \in [0, \infty)$, $\{A_\lambda\}_{\lambda \in [0, \infty)}$ מהשאלה מוגבלת מהשאלה מוגבהת ↪

• מינימיזציה $\lambda = 0$ מהשאלה מוגבלת : bias-variance tradeoff - \rightarrow מינימיזציה

• מינימיזציה $\lambda = \infty$ מהשאלה מוגבהת ($h = 0$) מינימיזציה bias

• מינימיזציה λ מהשאלה מוגבלת ($h = 0$) מינימיזציה bias

soft SVM

Grouped feature half-space rule called KID: Soft SVM

לפיה מינימיזציה של פונקציית האפסון: $\min_w \parallel w \parallel_2^2 + \frac{1}{m} \sum_{i=1}^m \xi_i$

$$y_i \cdot (\langle x_i, w \rangle + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \quad : P_3 \rightarrow \mathbb{R}$$

Ex. Pipe (DP) $\|w\|^2$ (i) fidelity term is non

margin -> 2 margin w - e

בוקס פונקציית האפסון $\frac{1}{m} \sum_{i=1}^m \xi_i$ (כגון regularization term)

ב-133 ניכר כי הנטען מנסה לטעות בטענה כי הכתובת היא מזוינה.

յայ ըրուն, fidelity term -> յայ հետո λ -ը ուկը ի՞ր *

... superimposed as scale, regularization term \rightarrow

▷ ANF 1981, 1985. FIGURE 10.20 (L) AVERAGE PROXY ANFN ←

, $L_S(b)$ cone fidelity term- ρ $3pN\lambda J$ $\gamma = R$, $\chi = R^J$

- $\boxed{l(h(x), y) = (h(x) - y)^2} \therefore$ Squared loss loss \rightarrow 'pura' f. melind

10, 123) 1251 (ERM-5.0251)

13:11 2013 CART 1

(Ridge Regression קידום גסאר כוכב גיבוב) 3

(The Lasso (לָסֹו) וְהַלְכָה (הַלְכָה) גַּם כִּי יֵשׁ לְעָמֵד בְּלֹא לְלִזְמָרָה)

(CC) fidelity term -
discusses length of time per task ★

ℓ_1 -regularized logistic regression - $\text{logit}_{\text{TERM}} = \text{N}$ γΝ

CART BY DODGE 38 1

ב. גורן, גולן ור' נירון: מילוי הדרישה הלאומית כמשמעותה של מדיניות חוץ

36 प्राचीन स्तर की classes जिनमें वास्तव में विभिन्न प्रकार की प्रौद्योगिकीय विधियाँ दर्शाई गई हैं।

• የዚህን ነጥቦች ማስረጃዎች የሚከተሉት የሚከተሉት በቻ ማስፈጸም ይችላል, multi-class-classification

...nks p3f n1p1e CART 1c1ci 211'0 3f 1.5c 22 38

ას პირი . მეტად ასეთი ასიმულაცია არ არის რა დანართობის მიზანი.

$\{c_j\}_{j=1}^d \subset R$: $\int_G \lambda \cos(p) \lambda \cdot \lambda \in \text{range } \int_G e \cdot e = 0$

הנחתה $h: \mathbb{R}^d \rightarrow \mathbb{R}$ מוגדרת כ $h \in \mathcal{H}_{RT}$.

$\mathbb{1}_{B_j}$ 를 ω 에, $h(x) = \sum_{j=1}^N c_j \mathbb{1}_{B_j}(x)$ 는 \mathcal{X} 의 N 개의

• Bְּיַהוָה כִּי תְּבִרְכֵנִי וְתִּמְלִיכֵנִי בְּעַמְּךָ יִשְׂרָאֵל

לעומת ה דיאטוניקו-טוניון, מנגינה זו מוגדרת כטונית.

$\{\pm 1\} \rightarrow \text{sign}(f) \in \mathbb{R}$ es en suyo la función signo de sign

* רוחן של יפה נוף ורשות הרכבת מ-RTHT

• נסיגת הרים נסיגת הרים

הנורווגיה נספחה לבריטניה בשנת 1814.

empirical risk \rightarrow גיבוב ניסויים: \hat{f}

• (1) מתקיימת נסיעה מ- \mathbb{R}^n ל- \mathbb{R}^m .

המודול הנקרא CART מגדיר top-down, מילויים נספחים:

הנורם מושג מהתוצאות של הבדיקה.

$$\therefore x_1, y_1, \dots, y_k \in \mathbb{R} \quad \text{I.e., } \therefore \text{1. } x_1, \dots, y_k \quad ? \text{ DNE}$$

$$\bar{y} = \frac{1}{k} \sum_{i=1}^k y_i : \text{y3INN, i) CID } \quad \bar{y} = \underset{c \in \mathbb{R}}{\operatorname{arg\,min}} \sum_{i=1}^k (y_i - c)^2$$

ასეთი კონტროლის მიზანი არის $c_j = \text{ave}(y_i)$ და $y_i \in B_j$ უნივერსიტეტის მიმღები მიმღები მდგრადი დანართის მიზანი.

ב-CART מוגדר גוף $B_0 = \mathbb{R}^d$ ותבנית π מוגדרת כפונקציית מילוי $\pi: B_0 \rightarrow [0, 1]$.
תפקידו של הגוף B_0 הוא לספק אוסף של נקודות במרחב ה- d -ממדי, ותפקידו של המילוי π הוא לספק אוסף של נקודות במרחב ה- d -ממדי, שטף על נקודות במרחב ה- d -ממדי.

★ תרגום מילויים - פון אונטראקיון (לטינית) → handout

הנחיות הדרישות מפונקציית פיקט היא:

- גודל נסיעה נמוך יחסית למספר המרוצחים
- גודל נסיעה נמוך יחסית למספר המרוצחים

רְגִזְעָן גַּדְעֹן מִזְמֹהֶת, אֲמַנְקָוָאֵל גַּדְעָן לְפָנָי.

$\mathbb{R}^d = \bigcup_{j=1}^N B_j$ נגזרת יפנית וריאנטה T של ס-פרן נpj : פאלט

$$L_S(T) = \sum_{j=1}^N \sum_{i: x_i \in B_j} (y_i - y_S(B_j))^2$$
 יפנית T יופת ריבועים נלקות

போல முடிவு ஒன்று : To be off - in kin T pic TCT. 737

• $\text{AlCl}_3 + \text{SiN}_4 \xrightarrow{\text{heat}} \text{TiAlSiN}_x$

נזכיר כי אם T הוא מושג פיזי, אז $R(T) = |T|$.

$$\min_{\tau \in T_0} \{ L_s(\tau) + \lambda |\mathcal{T}| \}$$

ESL.9.9.2-p סענן ! כ ?sy. WIN.N v. ple>

16.0 **16.0** **(ב) נזק נרחב (א) נזק מוגבל (ג) נזק מוגבל נרחב:**

ליכיך:

הוכחתו של הטענה: $H_{lin} = \left\{ h \mid h(x_1, \dots, x_d) = w_0 + \sum_{i=1}^d x_i w_i, \quad w_0, \dots, w_d \in \mathbb{R} \right\}$

פָּלָסִין יְנַיֵּלֶת הַמִּזְרָחָה (לְאַלְפֵי שָׁנָה מִנְדָּם) פָּלָסִין יְנַיֵּלֶת (*)
 (square loss loss - ה' פָּלָסִין רְגַלְתָּם) least squares .

• מגדיר פונקציית סינוס אלגברית

גַּדְעָן רְבִנְיָה אֶתְּנָא מֵכָל הַמִּינָּה וְעַל *

1. גנטיה וריאציות גנטיות מוגבלות מוגבלת

... as we as if you will not be able to do so, please let us know.

110-118 P. 33 NADP P. 218 ACF DO 36 UICR P. 3 NIS →

medico medico relapsing multiple sclerosis

? poly) N

ריצוף וריאציות מינימום גודלו של השגיאה $\|w\|$ נקרא **regularization**.
 מינימום גודלו של השגיאה מוגדר כ**intercept**.

Best Subset Selection \rightarrow נספחים

$$\underset{\mathbf{w} \in \mathbb{R}^d, w_0 \in \mathbb{R}}{\text{minimize}} \quad \|w_0 \cdot 1 + \mathbf{x}^T \mathbf{w} - y\|^2 \quad \text{subject to: } \|\mathbf{w}\|_0 \leq t$$

Best Subset Selection

• (non) zero $\|v\|_0 = \#\{i : v_i \neq 0\}$, $v \in \mathbb{R}^n$

ולכן $\lim_{t \rightarrow \infty} Ls(h) = 0$ ו- $Ls(h)$ מוגדרת כפונקציית גבול.

: bias-variance tradeoff -> היפר-פרמטרים, ת. נס. פג'ר ור'ה
 פונקציית פג'ר (bias-variance tradeoff function) מגדירה את היחס בין הביאס
 לבין קווינטיל ה- α (quantile), כלומר בין \hat{y}_i ל- y_i . אינטגרל של פונקציית
 פג'ר מוגדר כ-

א) כוונת הכתובת מוסיפה למשמעותה של המילה (בהתאם למשמעותה בפונטיקה) ומשתנה בהתאם למשמעותה במשמעותה הדרומית (בהתאם למשמעותה בפונטיקה).

$$\begin{aligned} & \text{minimize}_{w \in \mathbb{R}, w \in \mathbb{R}^d} \|w_0 \cdot 1 + x^T w - y\|^2 \\ & \text{subject to: } \|w\| \leq t \end{aligned}$$

למי סבירו קידוחה הדרגתית מיותרת? precise less less: מטרת היערכות נזקiva tradeoff \rightarrow מטרת

$$L(\omega_0, \omega) = \sum_{i=1}^m (\omega_0 + \langle \omega, x_i \rangle - y_i)^2 \quad : \text{ (c) fidelity} \rightarrow *$$

א. ω מוגדרת כפונקציית ריבועית $R(\omega)$ בקטע $[0, \pi]$.

- 1.3. גורם ה-Norm $\|v\|_2 = \sqrt{\sum_{i=1}^d |v_i|^2}$: ℓ_2 ה-Norm
- $\|v\|_1 = \sum_{i=1}^d |v_i|$: ℓ_1 ה-Norm
- $\|v\|_0 = \#\{i | v_i \neq 0\}$: ℓ_0 ה-Norm

$\underset{w \in \mathbb{R}^d, w_0 \in \mathbb{R}}{\operatorname{arg\,min}} \|w_0 \cdot 1 + x^T w - y\|_2^2 + \lambda \|w\|_2^2$: Ridge Regression

$$\underset{w \in \mathbb{R}^d, w_0 \in \mathbb{R}}{\operatorname{arg\,min}} \|w_0 \cdot 1 + x^T w - y\|^2 + \lambda \|w\|_1 : \text{Lasso}$$

$$\underset{\mathbf{w} \in \mathbb{R}^d, w_0 \in \mathbb{R}}{\operatorname{argmin}} \|w_0 \cdot 1 + \mathbf{x}^T \mathbf{w} - y\|^2 + \lambda \|w\|_0 : \text{Best Subset Regression- \delta method}$$

רתקין שגדל ב-3 מטרים כ- $\lambda = 0$: מינימום נגדי ל- $\lambda = \infty$

w_0 intercept -> מינימום נגדי ל- $\lambda = \infty$: מינימום נגדי ל- $\lambda = 0$: מינימום נגדי ל- $\lambda = 0$

למינימום נגדי ל- $\lambda = 0$: מינימום נגדי ל- $\lambda = \infty$: מינימום נגדי ל- $\lambda = 0$

3 מטרים כ- $\lambda = 0$: מינימום נגדי ל- $\lambda = \infty$: מינימום נגדי ל- $\lambda = 0$

רתקין גודל כ- $\lambda = 0$: מינימום נגדי ל- $\lambda = \infty$: מינימום נגדי ל- $\lambda = 0$

l₀-regularized linear regression (2)

Best Subset Selection: מינימום מושג רציף וריבועי גודל

$$\underset{w_0 \in \mathbb{R}, w \in \mathbb{R}^d}{\operatorname{argmin}} \|w_0 + X^T w - y\|^2 + \lambda \|w\|_0 : (\text{מינימום נגדי ל-} \lambda)$$

(intercept -> l₀)

פונקציית נגדי ל- λ fidelity term -> tradeoff

מינימום מושג רציף וריבועי גודל (מינימום נגדי ל- λ)

מינימום מושג רציף וריבועי גודל (מינימום נגדי ל- λ)

מינימום מושג רציף וריבועי גודל (מינימום נגדי ל- λ)

מינימום מושג רציף וריבועי גודל (מינימום נגדי ל- λ)

Ridge Regression (3)

$$- R(w) = \|w\|_2^2 : \text{כינוס מושג רציף וריבועי גודל}$$

$$\underset{w_0 \in \mathbb{R}, w \in \mathbb{R}^d}{\operatorname{argmin}} \|w_0 + X^T w - y\|^2 + \lambda \|w\|_2^2 : (\text{מינימום נגדי ל-} \lambda)$$

רתקין שגדל כ- $\lambda = 0$: מינימום נגדי ל- $\lambda = \infty$

מינימום נגדי ל- $\lambda = \infty$: מינימום נגדי ל- $\lambda = 0$

Tradeoff: מינימום נגדי ל- $\lambda = 0$: מינימום נגדי ל- $\lambda = \infty$

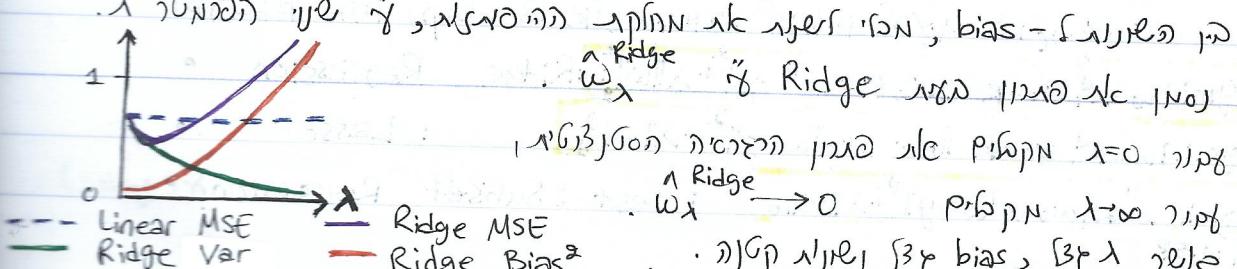
מינימום נגדי ל- $\lambda = 0$: fidelity term -> מינימום נגדי ל- $\lambda = \infty$

($\lambda > 0$): מינימום נגדי ל- $\lambda = 0$

אפקט Ridge: מינימום נגדי ל- $\lambda = 0$: מינימום נגדי ל- $\lambda > 0$

מינימום Ridge: מינימום Ridge מינימום Ridge

מינימום Ridge: מינימום Ridge מינימום Ridge



• x le SVD-ה נוציאו גורוכו הנקרא אטומס ? מ-רעהם כ-א
 x le SVD-ה פותח $x = u \sum v^T$ כפ-ר-ט-ו כ-א ג-ו-ג-ו (ANOVA) א-ר-ע-מ א-כ-י-ם ו-ר-ע-מ.

$$\text{diag}(\Sigma^\lambda) = \frac{\sigma_i}{\sigma_i^2 + \lambda} : \text{IPF} \quad \hat{\omega}_\lambda^{\text{Ridge}} = u \Sigma^\lambda V^T y : P' P M : \text{PCA} \rightarrow \text{PCA}$$

לינק ופונקציית Ridge: רוגראם שוכן ב-הפרמטרים נסמן $\hat{\beta}$ ו-המטריצות נסמן $X^T X$.
המטריצה $X^T X$ מוגדרת כ-המטריצה $X^T X = \sum_{i=1}^n x_i x_i^T$, כלומר $X^T X = \sum_{i=1}^n x_i x_i^T$.

Lasso Regression

$$\text{הוכחה גיאומטרית כמודרנית לינארית} \quad R(\omega) = \|\omega\|_1 \quad \text{.argmin}_{\omega \in \mathbb{R}, \omega_0 \in \mathbb{R}^d} \|\omega_0 - x^\top \omega - y\| + \lambda \|\omega\|_1$$

በዚህ የሚከተሉት ስልክ በመሆኑ እንደሆነ የሚከተሉት ስልክ በመሆኑ እንደሆነ

پیچیده‌ترین Ridge و Lasso ها را در اینجا معرفی نمایم.

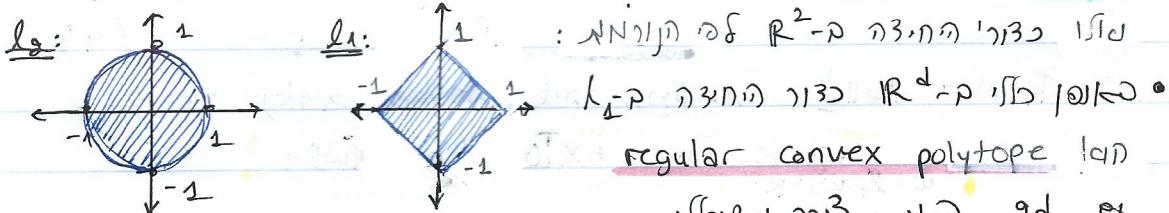
(λ מינימום) ר.ס.ב. פה ג'ן Lasso - ל. ר.ג.ג. הוגדרו: λ מינימום ביחס ל.ר.ג.ג.

ג) ידרשו, ונהק לאריך ש. וינהן גע. ה.ו. קוויקסילר, גוט ו
העכבר ערכיסלר, ואטלי אט ניאן הצעה. ב.ג. דב בענין.

הנושאים - Subset Selection ו-BPN: Lasso ו-GLM ו-GBM
 (lambda) Lasso יפ' מושג רצוי מושג features מהם כוכב. active set הוא מושג - מושג רצוי מושג active set והוא מושג interpretability - מושג active set. מושג active set מושג GLM, מושג BPN, מושג GBM. מושג active set מושג GLM, מושג BPN, מושג GBM.

גַּנְגָּה כְּלָל. קָרִינָה רַמְּגָּר ? פְּרִזְבִּיזְמָר

$$\rho \in \mathbb{R} \text{ such that } \{w \in \mathbb{R}^d \mid \|w\| \leq \rho\} \text{ is compact}$$



: (የዚህ ማስረጃ በፊት እና ማስረጃ በፊት የዚህ ማስረጃ በፊት)

minimize $\|w_0 + x^T w - y\|$, subject to $\|w\|_2 \leq t$: Ridge PIPNP *

$\min_{w \in \mathbb{R}^d, w_0 \in \mathbb{R}} \|w_0 + X^T w - y\|_1$, subject to: $\|w\|_1 \leq t$: Lasso P1PNP

בנוסף לasso, Ridge \rightarrow מינימיזציה של פונקציית האפסון-הרבובית (LSE) עם גזירת מינימום מוגבלת.

↳ Lasso, Ridge 와 같이 규제 항목에 β 의 제곱을 더해준다. ↳ $\hat{\beta} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$

? $\lambda - \{ + \cdot p \mid \text{on}, \text{in} \text{ p} \}$

. polynomial features - הינה $I = XX^T$ ובל נזכיר λ - 2
 רצוי I להיות אורתוגונל (orthogonal) למשולש.

- $\lambda > 0$, $x \in \mathbb{R}$ ור' : מילוי $\lambda \in \mathbb{R}$ בהטרנספורמציה והפונקציה.

- Soft threshold λ - $n_{\lambda}^{\text{soft}} : \mathbb{R} \rightarrow \mathbb{R}$

Hard threshold λ - $n_\lambda^{\text{hard}} : \mathbb{R} \rightarrow \mathbb{R}$, $n_\lambda^{\text{hard}}(x) = x \cdot \mathbf{1}_{|x| \geq \lambda}$

(\hat{w}_{Subset} , \hat{w}_{Lasso} , \hat{w}_{Ridge} , \hat{w}_{LS}) : $f(\mathbf{x})$

Best Subset Solutions , Lasso , Ridge , least squares

orthogonal design - $P_{\{j\} \cup k}$ $\Rightarrow n : \mathbb{R} \rightarrow \mathbb{R}$ $\hat{P}_{\{j\} \cup k} w \in \mathbb{R}^d$ if $\hat{w} \neq 0$

$$\hat{w}_\lambda^{\text{Ridge}} = \hat{w}^{\text{LS}} / (1 + \lambda), \quad \hat{w}_\lambda^{\text{Lasso}} = n_\lambda^{\text{soft}} (\hat{w}^{\text{LS}}) \quad : \text{"if } p \gg n \text{ then } \lambda \text{ is large"}$$

$$\hat{w}_\lambda^{\text{subset}} = \underset{\lambda}{\operatorname{arg\,max}} \hat{w}^{\text{LS}}(\lambda)$$

! als : le Tap Gs uninvariant shrinkage functions

• Online Auctions

בנה שרכזת גנבה כוונתית נורכע מזוכג?

אנו מודים לך על תרומותך ותומךך למדינת ישראל.

ההשׁתָּמֵן (interpretation) מושג זה נקבע בהמונחים: דוגמא לילכ מנד פילכ

• ⑧ ... 3781 የሱ ስርጓኝ የዕግዢና የዕንድጂና (ዚህን አገልግሎት ተስተካክለ ይችላል) የዕግዢ የዕንድጂና የዕግዢ የዕንድጂና

$$\hat{\omega} := \operatorname{argmax}_{\omega \in \mathbb{R}^d} \sum_{i=1}^m [y_i(\omega_0 + \langle x_i, \omega \rangle) - \log(1 + e^{\omega_0 + \langle x_i, \omega \rangle})]$$

(.. w -> lcf $\omega_0 \in \mathbb{R}$ intercept \rightarrow lcf)

$$F_s(\omega) = \sum \left[\log\left(1 + e^{\omega_0 \langle x_i, \omega \rangle}\right) - y_i (\omega_0 + \langle x_i, \omega \rangle) \right] : \text{left fidelity term} \rightarrow \text{NIS}$$

ב. מינימיזציה של פונקציית האנרגיה במודל/logistic regression regularized by L1

- $\lambda \|\mathbf{w}\|_1$... (Lasso loss) fidelity term - if $R(\mathbf{w}) = \|\mathbf{w}\|_1$

$$\underset{w \in \mathbb{R}^d}{\operatorname{argmin}} \left[\sum_i \left[\log \left(1 + e^{w_0 + \langle x_i, w \rangle} \right) - y_i (w_0 + \langle x_i, w \rangle) \right] + \lambda \|w\|_1 \right]$$

(۱۰۳ ص) ! پیش از پرداخت پردازش این را با کجا می‌توان

לעומת solvers כמו *prism*, *cong*, *z3* ו-*mathsat*

3. גן (λ בפ) הוא גן נאכטוני, לא רגולרי.

⑩ מִתְּמֻנָה וְמִתְּמַנֵּן ? לֹא כַּיְדֵי קַוְעֲדָה שֶׁ

• גיינטcept-סֵרְבָּרְגִּינְסְּ (Giantccept-Serbergins) מושב נס ציונה.

(Forest-!) CART Regression Tree A regressão é o tipo de árvore:

נווילס - glmnet מתקנה מומלצת לניתוחים של קבוצות Best subset

רמלה ואופק על ים ים, הנקראים עתה ים ים. בלאם אין מודרני

penalty, (cross-validation step size) λ to avoid overfitting

... 300 ուշական , պայ 713 , l_1, l_2 աւ շպնչ

• גן נוירלי אטטי (elastic net) (אנוילס)