

19/6/20-1

#10 11311

- (Supervised batch learning) מתקין גנריים נספחים ל-
תבניות נוכחות נרwan, x ו- y ה- x ה- y .

: לפניהם נקבעו המקומות הנכונים - במיון הנוסף לפניהם הנקבעו המקומות הנכונים במיון הנוסף

: 112 1182 3 (3)

. հԱՅՅԱ ՅՆ-ԴԻ ՀԱՅԱ ԽՈՅ : Uncovering low-dim structure

OpenBLAS 0.3.1c (C 1024x1,024) using bin file dataset -> E13

סמלרים סוריים. מילון נינן וטוקטוקי R^{1,024 × 1,024}

3M:N. refNds, RGB-P Alims. IR: 3x1,024 x 1,024

הסכמה הינה רק כנה וכיוורע סליחה מילג'ן בוגד לנויה נושא. כוון

אנו נאבקים בפיג'ם

• 28x28 גִּיאוֹגְרַאֲפִיָּה מִינְיָה 3, וְלֹא נִזְמַנְתָּה לְכַלֵּל אֶלְגָּוֹרִיתְמִים dataset).

אנו נראה ש μ מוגדר על \mathbb{R} ו- μ מוגדר על \mathbb{R}^n

շաբաթի, "1", "1", "1" մարդուց անկ ուշադիրք ունի վեճ . ԲՅՆ'Ն

וְאַתָּה תִּשְׁמַע בְּזָבֵחַ כִּי אֲלֹהִים וְאֶתְנָחָתָה (אֲלֹהִים וְאֶתְנָחָתָה) וְאַתָּה תִּשְׁמַע בְּזָבֵחַ כִּי אֲלֹהִים וְאֶתְנָחָתָה.

: ($K < d$) \mathbb{R}^K 3NN များ၏ \mathbb{R}^d 3NN အတွက် N_c များ၏ အပြောင်းလဲမှု

... 3 נטול מושגים, dataset -> גודל ומרקם? ?

ԱՅՑՈՐԺ ԲՐԱՅԱՆԻ ՀԱՅ և ՇՆԵՐ (ԱՄՓԱԼԻ ԴՐԱ) : Clustering

የፍትሬ የዕለታዊ ሪፖርት በመስራት እና የዕለታዊ ሪፖርት በመስራት እና

בנוסף לשליטה על היבטים טכניים, כוונתנו היא לסייע לך בפתרון בעיות יומיומיות.

הdataset -> סיבובים (Iteration), פונקציית איסוף (Sampling Function) ופונקציית חישוב (Computation Function)

• D. Python file project

ԱՅՆ Հ-Ը (ՀԱՅԻ ԼՋ) ԽՈՅՑՆ ԱՅ ՊԻՆ ԽՅ) clustering-ը ↪

• **לעומת** ה^ר יגאל ע' פָּרֶס גַּם (ה' ו' יגאל ע' פָּרֶס גַּם)

הנתקה בזיהוי אונומלי (Anomaly Detection) מושג באמצעות מודל שמייצג נורמלית נתונה. מודל זה מקבל כקלט מידע על נתונים מסוימים ובודק אם נתונים חדשים מושגים מהתמודל נורמליים או לא. מושג זה מוגדר כפונקציית מילוי (filling function) μ , $\{\mathbf{x}_i\} \subset \mathbb{R}^d$ נתונים מוגדרים כנתונים נורמליים אם $\mu(\mathbf{x}_i)$ מושג מילוי מושג.

- Principal Component Analysis (PCA) : באנליזה פונטיאלית 1
- K-means clustering : קלאסיפיקציית קבוצות 2

PCA (הכלור נינט פיזיולוגיה) 1

לפיכך אם $\{x_i\}_{i=1}^m \subset \mathbb{R}^d$ אז
 $\omega: \mathbb{R}^d \rightarrow \mathbb{R}^k$ מוגדרת על ידי
 $\{\omega(x_i)\}_{i=1}^m = \omega(\{x_i\}_{i=1}^m)$

הנתקה מכם ורשותם נזקפת בכם ותוקףם נזקפת בכם

ב-הארק מ-גראן מ-הנוקד מ-הנוקד מ-הנוקד מ-הנוקד מ-הנוקד

לפניהם נסמן \mathbf{w}^k ו- \mathbf{w}^{k+1} , ו- \mathbf{w}^k מוגדר כ-

DEFINITION: $x \in \mathbb{R}^d$ is called a point in an interval if it belongs to the interior of the interval.

לעתה נסמן את הנקודות על ציר ה- x ונקראים נקודות אינטגרציה. נסמן את הנקודות x_0, x_1, \dots, x_n ונקודות האינטגרציה $a = x_0 < x_1 < \dots < x_n = b$.

PCA

• $\sum_{i=1}^m \|x_i - w\|_2^2$: מינימיזציה נורמה ריבועית של שטף

ארכז גנרטור מושגנו ע. ו. דיניג עט. מילון ארכז גנרטור

$$\underset{\substack{w \in \mathbb{R}^{d \times k} \\ u \in \mathbb{R}^{d \times k}}}{\operatorname{argmin}} \sum_{i=1}^m \|x_i - uw\|_2^2 \quad \text{subject to } \{x_i\}_{i=1}^m \subset \mathbb{R}^d \quad \text{PCA algorithm}$$

$\hookrightarrow \mathbb{P} = \text{Im}(u\omega)$ چنانچه $k \geq 3N$ $u\omega \in \mathbb{R}^{d \times d}$ باشد. $k \geq 3N$ \mathbb{R}^d را پوشانند.

$\|x_i - u\omega x_i\|^2$ הינו שטף נסיעה על $x \mapsto u\omega x$ כפודם של x_i .

רמי שתקין זה

לפנינו נציג מושג אחד שנקרא V ו- V^T . מושג זה מוגדר כ-

$$\|x - uu^T x\|^2 = \|x\|^2 - 2x^T uu^T x + x^T uu^T uu^T x =$$

$$= \|x\|^2 - x^T uu^T x = \|x\|^2 - \text{trace}(u^T x x^T u)$$

rank 1 in NDS

$$\text{Nc } \underline{\text{PONF}} \text{ (5)), } \|x - uwx\|^2 = \|x - uu^T x\|^2 \text{ Nc } \underline{\text{S(CNS) 3))} \text{ pd)} \\ \text{trace} [u^T (\sum_{i=1}^m x_i x^T) u] \\ \begin{matrix} u \in \mathbb{R}^{d \times K} \\ uu^T = I \end{matrix} \underbrace{A}_{\text{NOT}}$$

(positive semidefinite) $A = UDV^T$: D מושכלת של A , D מושכלת של A^T

$$\text{trace}(u^T \cdot A \cdot u) \leq \sum_{i=1}^K D_{ii} u_i \quad (A \in \mathbb{R}^{n \times n}, D_{ii})$$

„(עֲמָקָם וְעַמְקָה כִּי כֵן כִּי כֵן) עַמְקָה כִּי כֵן כִּי כֵן

תְּמִימָנָה וְתְּמִימָנוֹת

כפי ש A ככ.anine' ככ. ני'.

A se ſin pă u u i i n g r o p i r e l e , p 3 , r o n m a g e p o p) *

כדי שגורסagi ו"תרכזת" מילוי נוגע...

የምራጥ የጊዜና ተ ማስተካከል ይችላል እና የሚያስፈልግ የሚያስፈልግ የሚያስፈልግ የሚያስፈልግ

பிரபுவி நீங்களுக்கு இல்லை, அதே போன்று

$$\text{trace}(\tilde{u}^T A \tilde{u}) = \sum_{i=1}^k d_{i,i}$$

$$\boxed{1} \quad \text{Q3) } \tilde{u} \in \arg \max_{\substack{u \in \mathbb{R}^{d \times k} \\ u u^T = I}} \text{trace} \left[u \left(\sum_{i=1}^m x_i x_i^T \right) u^T \right]$$

• גירז ראיון נציגות ג'פלו גראן גויאן

পৰিবহন প্ৰক্ৰিয়াৰ জোড়ে নিৰ্বাচিত কোৱা হৈলৈ একজন সহকাৰী

$$w(x) = \tilde{w}(x - \mu) \quad \rightarrow \text{lop\> } \text{nn3N} \text{ lop\> } w: \mathbb{R}^d \rightarrow \mathbb{R}^{k-l} \quad \text{לעדי}$$

$\mu \in \mathbb{R}^d - \{0\}$ נקרא ב- $\tilde{\omega}: \mathbb{R}^d \rightarrow \mathbb{R}^k$ מילוי

μ f_b አንድናገዕለ የ PCA-ን ስራ አንድናገዕለ ተያያዥ ይችላል ጥሩ

$$\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i \in \mathbb{R}^d - \text{an } \mathcal{N}(\mu, \Sigma) \text{-distributed sample}$$

• P31 (N) γενίσια

PCA → מגדיר מילויים נספחים למשתנים, שמייצגים מילויים נספחים למשתנים.

$$A = \sum_{i=1}^m (x_i - \bar{x})(x_i - \bar{x})^T$$

(! sample covariance \rightarrow גורם נורמליזציה)

PCA (Principal Component Analysis) is a dimensionality reduction technique that transforms the original features into a new set of features called principal components. These components are orthogonal to each other and capture the maximum variance in the data.

: 1) PCA ְּרִאשׁוֹנָה גַּם הַחֲזָקָה שֶׁ

$$\underset{\mathbf{w} \in \mathbb{R}^{d \times k}, \mathbf{u} \in \mathbb{R}^{k \times d}}{\operatorname{arg\,min}} \sum_{i=1}^m \|\mathbf{x}_i - \mathbf{u}\mathbf{w}^T \mathbf{x}_i\|^2 : \text{33번 .28 } \mathbf{u} \mathbf{w} \in \mathbb{R}^{k \times d}$$

לפניהם נתקה בזבזת הון וריבוי מילויים.

: sample covariance \rightarrow S_N (the $p \times p$ matrix of sample covariances) $\hat{\Sigma}_N$ is $p \times p$

$$W = u^T - \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x})(x_i - \bar{x})^T$$

. $\sum_{i=1}^m \{x_i\}$ $\in \mathbb{R}^d$ \rightarrow sample covariance Σ $\in \mathbb{R}^{d \times d}$ $\text{def} = \frac{1}{m-1} \sum_{i=1}^m (x_i - \bar{x})(x_i - \bar{x})^T$

Σ $\in \mathbb{R}^{d \times d}$ $\text{def} = \sum_{i=1}^m (x_i - \bar{x})(x_i - \bar{x})^T$

$\lambda_1, \dots, \lambda_d \geq 0$ $\text{def} = \lambda_1, \dots, \lambda_d$ $\in \mathbb{R}$ $\text{eig}(\Sigma)$

λ_i $\in \mathbb{R}$ $\text{def} = i$ -th principal value \rightarrow λ_i $\in \mathbb{R}$ $\text{eig}(\Sigma)$

$\{u_i\}_{i=1}^m$ $\in \mathbb{R}^d$ $\text{def} = i$ -th principal vector \rightarrow u_i $\in \mathbb{R}^d$ $\text{eig}(\Sigma)$

$\Sigma = \sum_{i=1}^m \lambda_i u_i u_i^T$ $\text{def} = \text{PCA}$ $\Sigma = \sum_{i=1}^m \lambda_i u_i u_i^T$

$\{u_i\}_{i=1}^m$ $\in \mathbb{R}^d$ $\text{def} = i$ -th principal component \rightarrow u_i $\in \mathbb{R}^d$ $\text{eig}(\Sigma)$

3. PCA

$x_i \in \mathbb{R}^d$ $\text{def} = \text{vector}$ \rightarrow PCA \rightarrow x_i $\in \mathbb{R}^d$ $\text{def} = \text{vector}$ \rightarrow PCA \rightarrow $x_i \in \mathbb{R}^d$

$u_1, \dots, u_d \in \mathbb{R}^d$ $\text{def} = \text{orthogonal basis}$ \rightarrow $u_i^T u_j = 0$ $\forall i \neq j$

$u_1, \dots, u_d \in \mathbb{R}^d$ $\text{def} = \text{orthogonal basis}$ \rightarrow $u_i^T u_j = 0$ $\forall i \neq j$

$x_i \in \mathbb{R}^d$ $\text{def} = \text{vector}$ \rightarrow PCA \rightarrow $x_i \in \mathbb{R}^d$ $\text{def} = \text{vector}$ \rightarrow PCA \rightarrow $x_i \in \mathbb{R}^d$

$x_i \in \mathbb{R}^d$ $\text{def} = \text{vector}$ \rightarrow PCA \rightarrow $x_i \in \mathbb{R}^d$ $\text{def} = \text{vector}$ \rightarrow PCA \rightarrow $x_i \in \mathbb{R}^d$

$\text{Span}\{u_1, \dots, u_k\}$

$x \in \mathbb{R}^d$ $\text{def} = \text{vector}$ \rightarrow PCA \rightarrow $x \in \mathbb{R}^d$ $\text{def} = \text{vector}$ \rightarrow PCA \rightarrow $x \in \mathbb{R}^d$

$x \in \text{Span}\{u_1, \dots, u_k\}$ \rightarrow PCA \rightarrow $x \in \mathbb{R}^d$ $\text{def} = \text{vector}$ \rightarrow PCA \rightarrow $x \in \mathbb{R}^d$

$x = \sum_{i=1}^k \langle x, u_i \rangle u_i$ \rightarrow PCA \rightarrow $x \in \text{Span}\{u_1, \dots, u_k\}$ \rightarrow PCA \rightarrow $x \in \mathbb{R}^d$

$x \in \text{Span}\{u_1, \dots, u_k\}$ \rightarrow PCA \rightarrow $x \in \mathbb{R}^d$ $\text{def} = \text{vector}$ \rightarrow PCA \rightarrow $x \in \mathbb{R}^d$

$x \in \text{Span}\{u_1, \dots, u_k\}$ \rightarrow PCA \rightarrow $x \in \mathbb{R}^d$ $\text{def} = \text{vector}$ \rightarrow PCA \rightarrow $x \in \mathbb{R}^d$

$(\langle x, u_1 \rangle, \dots, \langle x, u_k \rangle) \in \mathbb{R}^k$ \rightarrow PCA \rightarrow $x \in \mathbb{R}^d$ $\text{def} = \text{vector}$ \rightarrow PCA \rightarrow $x \in \mathbb{R}^d$

$x \in \text{Span}\{u_1, \dots, u_k\}$ \rightarrow PCA \rightarrow $x \in \mathbb{R}^d$ $\text{def} = \text{vector}$ \rightarrow PCA \rightarrow $x \in \mathbb{R}^d$

ההשנה בPCA

$x \in \mathbb{R}^d$ $\text{def} = \text{vector}$ \rightarrow PCA \rightarrow $x \in \mathbb{R}^d$ $\text{def} = \text{vector}$ \rightarrow PCA \rightarrow $x \in \mathbb{R}^d$

$x \in \text{Span}\{u_1, \dots, u_k\}$ \rightarrow PCA \rightarrow $x \in \mathbb{R}^d$ $\text{def} = \text{vector}$ \rightarrow PCA \rightarrow $x \in \mathbb{R}^d$

$d=3, k=2 \rightarrow$ PCA \rightarrow $x \in \mathbb{R}^3$ $\text{def} = \text{vector}$ \rightarrow PCA \rightarrow $x \in \mathbb{R}^3$

$\boxed{\{x_i\}_{i=1}^m \in \mathbb{R}^3, \text{PCA} \rightarrow \{u_1, \dots, u_2\} \in \mathbb{R}^3, \{x_i\}_{i=1}^m \in \text{Span}\{u_1, \dots, u_2\} \rightarrow x \in \mathbb{R}^3}$

ו-האחות הגדית כוונתית היא מינימיזציה של פונקציית האנרגיה

$$S = \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x})(x_i - \bar{x})^T \in M_{3 \times 3}$$

ההנחתה מינימלית מושגת על ידי $x_i = \bar{x}$ ו- \bar{x} מושג על ידי $\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$

מ-ההנחתה מינימלית מושגת על ידי $x_i = \bar{x}$ ו- \bar{x} מושג על ידי $\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$ ו- $x_i = \bar{x}$ מושג על ידי $x_i = \bar{x}$ ו- \bar{x} מושג על ידי $\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$

לפ-ההנחתה מינימלית מושגת על ידי $x_i = \bar{x}$ ו- \bar{x} מושג על ידי $\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$ ו- $x_i = \bar{x}$ מושג על ידי $x_i = \bar{x}$ ו- \bar{x} מושג על ידי $\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$

$x_i^T x_i$: מינימלי מושג על ידי $x_i = \bar{x}$ ו- \bar{x} מושג על ידי $\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$

x_i מושג על ידי $x_i = \bar{x}$ ו- \bar{x} מושג על ידי $\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$

מינימלי מושג על ידי $x_i = \bar{x}$ ו- \bar{x} מושג על ידי $\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$

$d > k \in \mathbb{R} - 1 \leq d \leq m - \{x_1, \dots, x_m\} \subset \mathbb{R}^k$:

$\{x_1, \dots, x_m\} \subset \mathbb{R}^k$: מושג על ידי x_1, \dots, x_m מושגים על ידי dataset

$\mathbb{R}^d \rightarrow \mathbb{R}^{k \times n}$ מושג על ידי \mathbb{R}^d מושג על ידי $\mathbb{R}^{k \times n}$

$k = 10 - \{x_1, \dots, x_m\} \subset \mathbb{R}^{10}$ מושג על ידי x_1, \dots, x_m מושגים על ידי dataset

$\mathbb{R}^{2500} \rightarrow \mathbb{R}^{10}$ מושג על ידי \mathbb{R}^{2500} מושג על ידי \mathbb{R}^{10}

מושג על ידי \mathbb{R}^{2500} מושג על ידי \mathbb{R}^{10} מושג על ידי \mathbb{R}^{2500} מושג על ידי \mathbb{R}^{10}

מושג על ידי \mathbb{R}^{2500} מושג על ידי \mathbb{R}^{10} מושג על ידי \mathbb{R}^{2500} מושג על ידי \mathbb{R}^{10}

מושג על ידי \mathbb{R}^{2500} מושג על ידי \mathbb{R}^{10} מושג על ידי \mathbb{R}^{2500} מושג על ידי \mathbb{R}^{10}

מושג על ידי \mathbb{R}^{2500} מושג על ידי \mathbb{R}^{10} מושג על ידי \mathbb{R}^{2500} מושג על ידי \mathbb{R}^{10}

מושג על ידי \mathbb{R}^{2500} מושג על ידי \mathbb{R}^{10} מושג על ידי \mathbb{R}^{2500} מושג על ידי \mathbb{R}^{10}

ב-ההנחתה מינימלית מושג על ידי $x_i = \bar{x}$ ו- \bar{x} מושג על ידי $\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$

ב-ההנחתה מינימלית מושג על ידי $x_i = \bar{x}$ ו- \bar{x} מושג על ידי $\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$

ב-ההנחתה מינימלית מושג על ידי $x_i = \bar{x}$ ו- \bar{x} מושג על ידי $\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$

ב-ההנחתה מינימלית מושג על ידי $x_i = \bar{x}$ ו- \bar{x} מושג על ידי $\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$

$\mathbb{R}^d \rightarrow \mathbb{R}^{k \times n}$

תירגול: רודריך גוטמן כוכב: רודריך גוטמן כוכב נורמאנית כוכב: רודריך גוטמן כוכב נורמאנית

. K=2 PC PCA P3,2N1

מ-בנין "בְּ" ב-בנין "בָּ" ב-בנין "בִּ" ב-בנין "בֵּ"

\hat{x} (preprocessing -> Numpy array NC PWDN)

$$\hat{f}(\lambda) = \bar{x} + \lambda_1 u_1 + \lambda_2 u_2 : \text{פונקציית מינימום}$$

$\alpha_i = \langle x, u_i \rangle$, $\lambda = "3"$ \Rightarrow

$\mathbb{R}^d \ni (u_1, \dots, u_k) \in \text{range}(p_{ij})$: p_{ij} הינה פונקציית מיפוי מ- \mathbb{R}^d ל- \mathbb{R}^k .

? אינטראקציית פולינומיאלית (polynomial interaction) מוגדרת כפונקציית תרשים המבוצעת על ידי מושג אחד (Variable) או יותר (Variables). אינטראקציית פולינומיאלית מוגדרת כפונקציית תרשים המבוצעת על ידי מושג אחד (Variable) או יותר (Variables).

(W.A.N.C) שאלת הנקודות מושגיה נקבעה בפער גדרה (בנוסף ל-10 נקודות).

בנוסף ל-PCA, פונקציית eigenfaces מגדירה פורסום (pose) ופומבי (lighting).

.dataset → Ø p,ø

:PCA → Principal Component Analysis

תְּמִימָנֶה בְּרִיחַת הַמִּזְבֵּחַ כִּי תְּמִימָנֶה בְּרִיחַת הַמִּזְבֵּחַ

ለ የሚገኘውን ተከራካሪ ስነዎች, (၁) ነገሮች ተከራክሩ ይችላል ይህም የሚ ስጠረዋል.

מבחן קובariance - Covariance

Re: 1525, 134 d 1106 pfi

(dxd kfi) mxm מatrice א-fin אלטנטיבית קיימת ? נורמליזציה ?

$O(m^3)$ if \mathcal{S}_f , \mathcal{P}_f

: Run PCA, $O(m^2 \cdot d)$ to run PCA yields weak points ←

• Input: $A \in \mathbb{R}^{m \times d}$ ($m, n, d \in \mathbb{N}$)

K($\lambda\theta_1 n$) $p_{B_N(N)}$ $'_N$)

- if ($m > d$):

$A = X^T X$ (X 는 C에 대해 행렬 X는 R에 속함)

let $\mathbf{L}_{1,\dots,K}$ be the eigenvectors of A with largest eigenvalues.

else:

$B = XX^T$ (\bar{x} 는 x 에 대한 평균 $x - \bar{x}$ 의 표준화)

Let $\mathbf{v}_1, \dots, \mathbf{v}_k$ be the eigenvectors of \mathbf{B} with largest eigenvalues.

for $i \in \{1, \dots, n\}$: Set $i = \frac{1}{\|x_i^T\|} x_i^T$

• Output: $1, \dots, K$

• $\text{MIN}_{\mathbf{X}} \parallel \mathbf{X}^T \mathbf{B} \mathbf{X}$ כוונת מינימום של $\mathbf{X}^T \mathbf{B} \mathbf{X}$ ו- $\mathbf{X}^T \mathbf{X}$ מוגדרת כפונקציית האנרגיה של מודולוס \mathbf{X} .

? KNC 2NPJ 3310

dataset ->N P'ANNEUN P'ANHIN IJGURSI P'AN" - 'N IUP K'EMI P'IC

\mathbb{R}^d ְ 3NN-ի ընդունակ էլեկտրոնային շահագործությունների համար:

$\mathbb{F} \hookrightarrow \Lambda . K \ 3N.NN \quad V \subset \mathbb{R}^d \rightarrow \text{P.BIN } \{x_i\}_{i=1}^m \quad n_{ijj} := \sum_{i=1}^m$

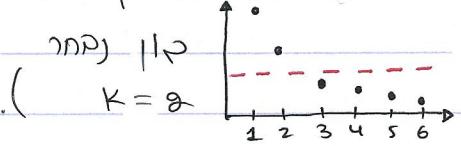
. $\{x_i\}_{i=1}^m$ be $d \times d$ \mathbb{R} matrix covariance \Rightarrow \mathbb{R} $d \times d$

$$\text{rank}(S) \leq K : \text{(rank)} \quad \dots$$

• סדרה של מילים ישרות ובלתי ישרות (בנוסף לדוגמה של מילה ישרה) \Rightarrow מילון מילויים (בנוסף לדוגמה של מילון מילויים)

לעומת \mathbb{R}^d ($d \geq 3$) מוגדרת פונקציית פוטון-טביעה $\rho_{\text{phot}}(x)$, שמייצגת את הסיכוי $P_{\text{phot}}(x)$ של קיומו של פוטון בזווית x .

החוקים נקבעו. בזאת קיימת אילו גורמים-הנוקט, אך ה' (בגדיים) לא.



K-Means - I Clustering (2)

clustering

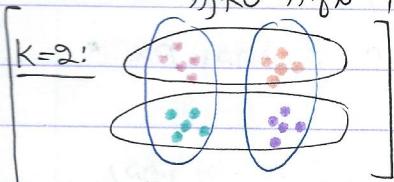
? clustering is done

לפנינו אוסף נתונים dataset -> קבוצה של נתונים על סדרה של מטרים

• $\text{End}^{\text{op}}(\mathcal{B}, \rho)$ bf

• **כונס תזרוקה שלחן גורו**, רכבה גבנער נוינער גראונטן קיילען דען זיין זיין.

לפניהם מתקיים קבוצת מילוי (filler cluster) שמייצג את המילויים (fillers).



נְאָזֶן וְלֹא שָׁמֵךְ רַבְנִים מִלְּרָא תְּמִיעָה הַכְּלִילִים,

Sample space -> ח�ט נספּה עיינָה נספּה

- \mathbb{R}^d 中の $x_1, x_2 \in \mathbb{R}^d$ の間の距離 $d(x_1, x_2) = \|x_1 - x_2\|$ (Euler 距離)

le nlinn npfn k!n p,1,p3 K-f $\{x_i\}_{i=1}^m$ dataset le clustering

$$\{x_1, \dots, x_m\} = \bigcup_{j=1}^k C_j \quad \because \text{A set of dataset} \rightarrow$$

- k -means clustering tip: 2,000 samples in 10 clusters

פָּרָץ־[כְּלַגְגָּן] פִּיכְנָן μj
("פְּנַסְׁתֵּן")

$$G(c_1, \dots, c_k) = \min_{\mu_1, \dots, \mu_k \in \mathbb{R}^d} \sum_{j=1}^k \sum_{x \in c_j} d(x, \mu_j)^2$$

$$c_j \in \arg\min_{\mu_j \in \mathbb{R}^d} \sum_{x \in c_j} d(x, \mu_j)^2$$

הוכחה: $d(x_1, x_2) = \|x_1 - x_2\|$: מינימום של $\|x - x_0\|$ ב- $x \in \mathbb{R}^d$

? G (k p_{1,N,j,N}) & C k³_N, j/k

NP-Hard \Leftrightarrow given if like P36 problem, Gijf problem, etc

الخطاب

K-Means

Դոյնե անօդական դաշտ, ՅԱՀ եւ ԲԱՀ բարձրացման համար կ-մեանս

G NC 2505

• 1, 3, \int_0^1 $|k \mapsto \pi_N(k)|^d$, $\chi = \mathbb{R}^d$: e. n. u.

Parallel

- **Input:** Set x_1, \dots, x_m and number of clusters k
 - **Setup:** Choose initial centroids μ_1, \dots, μ_k
 - Repeat until Convergence:

(1) Set C_j to be the points x_j closer to μ_j than to any other centroid.

(3) Update μ_j the centroid of C_j by: $\mu_j := \frac{1}{|C_j|} \sum_{x \in C_j} x$

נִגְדָּוֹת כְּמַלְחָמָה ?

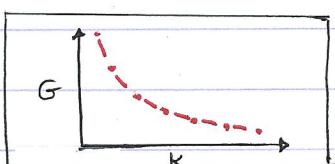
: 1st תרגום AN-PAN מילון היפני 3ኛ

: reinforcement (rɪn'fɔrməns)

cluster 6 גרעין, גנטוקן גן 301 (טערניאן) (1) (1-N-2)

13) ג. הגדוד נתקף בירקן ורתקן : מילוי תקון רתקן וירקן נתקף בירקן ורתקן : ג. הגדוד נתקף בירקן ורתקן : מילוי תקון רתקן וירקן נתקף בירקן ורתקן :

PINJN Σ_N PLC clustering-ה PINC, ופנויים נספחים להם
עקבות, רוחן.



? K NC 2NP, 33, 2

: bias-variance (le լուսաբառ է անդամ կամ ինք է)

ריבוים של מושגים נוראים הניתנים בפער רב בין ימינו ומיום ימי קדם.

(first K) will represent points in cluster 1, while others represent cluster -> 131p (6)

• 21. $P_{ij}C_j$ 3, $C_1 \cap C_2$ $\neq \emptyset$ $P_{ij}C_1 \cap C_2$ $\neq \emptyset$

training error \rightarrow מילויים נקיים \in כל הדוגמאות, KNN-P k=5 נקיים *

הנתקה מרים: מוגדרת כ-Overfitting - רושם אחד לאירוע אחד

בוקט ראנכט סולו G-e קהן, פירס ורונדה, סולו, ירושלים 14711

(3N 13) K 26) 3N 22) N [3] N

... λ α , β , γ , δ \in $\text{PGL}(V)$ such that $\lambda \alpha = \beta \gamma$