

25/5/20 - ס

תרגיל #8

בדבר ה- Boosting ^{טכניקה} משתמשים כדי לקבל תוצאה טובה יותר מ- confidence ו- accuracy .
 קיימים, וזיג, 2 טיפוסים עיקריים - לסיפור ה- confidence ולסיפור ה- accuracy .

(1) Boosting the confidence (שטח וצורה)

נתונים לנו T מודלים, $\{X_i\}_{i=1}^T \in \{\pm 1\}$ שמחזיקים גורם
 נכונה בסיבוי p , ומשוקה שלזיה בסיבוי $1-p$.
 נניח ש- $p > 1/2$. השאלה: אם נבצע לפי רוב ההשמות,
 מה הסיבוי שלצקנו? מה המודלים שסיבוי, חישוב הצסק הוור
 שקול למצוא: $\text{sign}(\bar{X}) := \text{sign}(\sum_{t=1}^T X_t)$.
 אלו חזרים למסלם אם ההסברות שלמה נכונה, למחר אם
 $P(\bar{X} > 0) = P(\text{sign}(\bar{X}) = 1)$

לפי p נחשב אם הסיבוי של ה- הממוצע (הממוצע):

$$\begin{aligned} P(\bar{X} \leq 0) &= P(-\bar{X} \geq 0) \stackrel{(a \in \mathbb{R}^+)}{=} P(-a\bar{X} \geq 0) \stackrel{(G \text{ האקספוננט})}{=} \\ &= P(e^{-a\bar{X}} \geq e^0) \stackrel{(אם מוקד)}{\leq} \frac{E[e^{-a\bar{X}}]}{e^0} = E[e^{-a\sum_{t=1}^T X_t}] = \\ &= E\left[\prod_{t=1}^T e^{-aX_t}\right] \stackrel{(X_t \text{ מודלים בסיבוי } p \text{ ו- } 1-p)}{=} (E[e^{-aX_1}])^T \stackrel{(X_1 \in \{\pm 1\})}{=} \\ &= (pe^{-a} + (1-p)e^a)^T = [e^a(1-p+pe^{-2a})]^T \stackrel{(1+x \leq e^x)}{\leq} \\ &\leq (e^a e^{-p+pe^{-2a}})^T \stackrel{(p > 1/2, a \in \mathbb{R}^+, p \in \mathbb{N}, a = \frac{1}{2} \ln(2p))}{=} \exp\left(T\left(\frac{1}{2} \ln(2p) - p + p \cdot \frac{1}{2p}\right)\right) = \\ &= \exp\left(Tp\left(-\frac{1}{2p} \ln\left(\frac{1}{2p}\right) - 1 + \frac{1}{2p}\right)\right) \stackrel{(\forall x \in [0,1]: x \ln(x) \geq \frac{1}{2}x^2 - 1/2 \Rightarrow x = 1/2p)}{\leq} \\ &\leq \exp\left(Tp\left(-\frac{1}{2(2p)^2} + \frac{1}{2} - 1 + \frac{1}{2p}\right)\right) = \\ &= \exp\left(-\frac{Tp}{2}\left(\frac{1}{(2p)^2} - \frac{1}{p} + 1\right)\right) = \exp\left(-\frac{Tp}{2}\left(\frac{1}{2p} - 1\right)^2\right) = \\ &= \exp\left(-\frac{T}{2p}\left(\frac{1}{2} - p\right)^2\right) \Rightarrow P(\bar{X} > 0) = 1 - P(\bar{X} \leq 0) \geq \\ &\geq 1 - e^{-T/2p(p-1/2)^2} \end{aligned}$$

למחר הסיבוי שלמה קטן בקצב $O(e^{-T})$ מהי!
 יחסים מודלים בסיבוי כזו אלקטין אם ה- confidence משתפר.

בדיון (שנסמך למטה) : עבור אלמנט $\{X_i\}_{i=1}^T$, מהי המוחלט
 מהי השונות של X_t ($t \in [T]$), ועבור הממוצע $\bar{X} := \frac{1}{T} \sum_{t=1}^T X_t$?

* הפעם תזכורו את \bar{X} שהוא הממוצע, בשונה מההעברה הקודמת.
 שלו. מכיוון שאנו מנסים למצוא סימן - sign, & ההנחה שקולות.

• $E[X_t] = 1 \cdot p - 1(1-p) = 2p - 1$ ←

$E[X_t] > 0$ כל $p > \frac{1}{2}$ ולכן

• $Var(X_t) = E[(X_t - E[X_t])^2] = E[X_t^2] - (E[X_t])^2 =$
 $= [p \cdot 1^2 + (1-p) \cdot (-1)^2] - [2p-1]^2 = 1 - 4p^2 + 4p - 1 =$
 $= 4p(1-p)$

• $E[\bar{X}] = E\left[\frac{1}{T} \sum_{t=1}^T X_t\right] \stackrel{\text{(ליניאריות)}}{=} \frac{1}{T} \sum_{t=1}^T E[X_t] \stackrel{\text{(לכל } X_t)}{=} E[X_1] = 2p - 1$

• $Var(\bar{X}) = Var\left(\frac{1}{T} \sum_{t=1}^T X_t\right) = \frac{1}{T^2} Var\left(\sum_{t=1}^T X_t\right) \stackrel{\text{(לכל } X_t)}{=} \frac{1}{T^2} \sum_{t=1}^T Var(X_t) =$
 $= \frac{1}{T} Var(X_1) = \frac{1}{T} \cdot 4p(1-p)$

שיטת הניסוי שכתבו משמרת את המוחלט החיוני כמו שלפני,
 אך מקטינה את השונות בקצב של $O(\frac{1}{T})$, ולכן ה-confidence צומח.
 הכיטחון ברמת הבדיקה $(1-\delta)$ בהעברת הניסוי (PAC - מוגדר עם
 מנגנון אקספוננציאלי m . לפי אסטרטגיה T מנגנונים כאלו
 ונמצא את הגורם m כפונקציה של δ ו- ϵ confidence שלפני!
אלפי: כמה שאלה נאמרו m - מנגנונים אחרים אחרת, ונפח הניסוי?
 כי כמה שהראינו כי יש מנגנון אחר:

Bootstrap : ציטטה קטנה ומפורסמת מאוד, כפי שזכרנו

m - מנגנונים שונים מאוד הם.

* אפשר להשתמש כמה שהשתנו בשלבים הללו ה-bootstrap! אלה

יש בעיה אחרת: תצגת ממוצע אינו קטן. הבעיה:

נניח ש: $\{X_i\}_{i=1}^T$ הם ממוצעים אקספוננציאליים, $Var(X_t) = \sigma^2$, והם גלויים: δ
 $Var(\bar{X}) = \frac{\sigma^2}{T}$: הבעיה : $Corr(X_i, X_j) = \rho : i \neq j \in [T]$

וכיכר: $Corr(X, Y) = \frac{Cov(X, Y)}{\sqrt{Var(X)Var(Y)}}$: $E[\sum_{t=1}^T X_t] = T\mu$: $E[X_t] = \mu$: μ : μ

$Var(\bar{X}) = Var\left(\frac{1}{T} \sum_{t=1}^T X_t\right) = \frac{1}{T^2} Var\left(\sum_{t=1}^T X_t\right) =$ ←

$$\begin{aligned}
 &= \frac{1}{T^2} \left[\mathbb{E} \left[\left(\sum_{t=1}^T X_t \right)^2 \right] - (T\mu)^2 \right] = \frac{1}{T^2} \mathbb{E} \left[\sum_{s,t=1}^T X_s X_t \right] - \mu^2 = \uparrow \\
 &= \frac{1}{T^2} \sum_{s,t=1}^T \mathbb{E} [X_s X_t] - \mu^2 = \\
 &\left[\begin{aligned}
 (\star) \rho = \text{Corr}(X_s, X_t) &= \frac{\text{Cov}(X_s, X_t)}{\sigma^2} = \frac{\mathbb{E}[X_s X_t] - \mu^2}{\sigma^2} \Rightarrow \\
 \mathbb{E}[X_s X_t] &= \rho \sigma^2 + \mu^2 \quad : s \neq t \text{ or} \\
 \sigma^2 = \text{Cov}(X_s, X_t) &= \text{Cov}(X_t, X_t) = \text{Var}(X_t) =: \text{variance} \\
 &= \mathbb{E}[X_t^2] - \mu^2 \Rightarrow \boxed{\mathbb{E}[X_t^2] = \sigma^2 + \mu^2}
 \end{aligned} \right] \\
 &= \frac{1}{T^2} \left[\sum_{s,t \in [T], s \neq t} (\rho \sigma^2 + \mu^2) + \sum_{s,t \in [T], s=t} (\sigma^2 + \mu^2) \right] - \mu^2 = \\
 &= \frac{1}{T^2} \left[(T^2 - T)(\rho \sigma^2 + \mu^2) + T(\sigma^2 + \mu^2) \right] - \mu^2 = \\
 &= \frac{1}{T^2} \left[(T^2 - T)\rho \sigma^2 + T\sigma^2(\rho + 1 - \rho) \right] = \frac{T-1}{T^2} \rho \sigma^2 + (1-\rho) \frac{\sigma^2}{T}
 \end{aligned}$$

Boosting the accuracy (2) (Adaboost)

משלשל בעקרון של weak learner כי להעביר אל הצורך.

מה ציכור לומד חוש? הן בלוג ϵ שגיאות:

Bias-Complexity Tradeoff - בעיה.

נסמן אל הפגון שהחזיר האל h - $h_s = A(s)$, ואל

הפגון הטוב ביותר ממחלק ההפגונים H $h^* = \arg \min_{h \in H} L(h)$


מסומנת שאלה, s_k :

$$L_D(h_s) = \underbrace{L_D(h^*)}_{\epsilon_{app} \text{ שגיאת הקורן}} + \underbrace{L_D(h_s) - L_D(h^*)}_{\epsilon_{est} \text{ שגיאת השעור}}$$

מקרים רבים שגיאת אלך באלו האחר ϵ חלשון השניה ϵ_{est} :

ההחזרה פולינומילית: $H_r = \{p: p \text{ פולינום ברמה } r\}$

נעזר אל ϵ (מאומ נפרט כמיצח הסיקוסט ϵ H):



כל מניע פשוט למצוא אל נק' האילון, אל

הקואנו לבחור r נשל אל עצמנו הינו

מחזיקים אלה: בצד ה"שמאל" (r נמוך)

אל בצד ה"ימני" (r גבוה). לרוב נעזר

אלה שמות כי נצפה שצדאל פול נמוכה

יפיו מקצמים גדולים יותר וקבל לומד חוש.

2. סיכוסט ממן היצה :

- מי אמר שיש להניח ERM בממן סביר? לא להיחסנו פסיכופג הי.
- היחס לחישוב ממן היצה פקור & המטלות -
- * מנגל היפוטזה הטובה ביותר (אמון).
- * שלוקר (פזיקציה) f דגימה חזשה, בהנח היפוטזה שמאני.

A הוא אלג' למיזה f אל הוא פלינומאלי ק-3 פמטרי:

- * m גול המצג ϵ * ϵ גול שגאל היזוק (נוזים אהגז אל ממן היצה כל ש $\epsilon \rightarrow 0$ $\epsilon \rightarrow \infty$ במזר כל ש)
- * ϵ גול שגאל (ה-confidence).

צולא: קול: גמונה גול 19×19 פיקסלים, כ"א מהפ מקב

סגר בו 0-555. פול: פהצור 1 אפ יש בממנה

פניס, 1- אפ אין. אל: $\chi = [956]^{19 \times 19}$, $\gamma = \{\pm 13\}$.

↔ באופן נאלי: נחש היפוטזה $\gamma \rightarrow [956]^{19 \times 19}$ h:

שטיכ למחוקר היפוטזה סיפג אכל צולה מאוז

נעצל עמחור אומז חוש שווי לא יחצי אל היפוטזה

הטובה ביותר, אכל יחצי משהו בממן סביר.

ג-לומז חוש: אלג' למיזה A ייקא ג-לומז חוש למור מחוקר

היפוטזה H כלשהא אפ קימא $\mathcal{M} \rightarrow (\{0,1\})$ מחמ עמורה על

$\delta \in (\{0,1\})$ וכל D הגפאל מל χ , אכל על פוף גגאל $f: \chi \rightarrow \{\pm 13\}$

המקימ אל פתח היאלניקליה ביחס ל- f, D, H אל אפ נק

$m \geq m_H(\delta)$ זגמול iid D שמיגאל f מקרי:

$$L_0(A(S)) \leq \gamma - \frac{1}{2}$$

מחוקר היפוטזה H ג-למיזה חוש: H וזו ג-למיזה חוש אל

קיימל ג-לומז חוש.

* ההקבל בו היצה צ להקצות למיזול-PAC הא שכל קעלנו אל ϵ

טלמ: למיזול-חוש גומה למיזול-PAC.

הוכחה: מהמשפט היסודי: אכל H ממיזול אכל צוולנו

לפמל $m_H(\epsilon, \delta) \geq C_1 \frac{d + \log(1/\delta)}{\epsilon}$ זגמול עקור $C_1 \in \mathbb{R}$ קול.

וקבט עקור $\epsilon = \frac{1}{2}$ גמאל צה מקרי. אחר, נניח שממזה ∞

במסגרת תא איננה למידת PAC אלא H לא יכולה להיגדר למידת חלש כי יש מספר אחר הנדרש להגדיר כמו ג'יטמור סופר.


במסגרת נים לאפיון למידת חלשה על מידת VC, כמו למידת PAC אלא מחמת מניי חלשה - יש לנו גרונן בשימוש במודל חלש.

דוגמה למודלים חלשים:


- נעמוד על מסד הנתונים MNIST (מאגר ספרות כתוב יד, בגודל 28×28). נבנה להפריד בין 0 ל-1. אלא נמקוט בקטקס פאמלץ ונקטן (הוא תואר כהה או בהיר). על-סמך ההבחנה זו נקנה מודלים - חלשים: $h_{ij} = \mathbb{1}_{[\text{pixel}(ij) \geq \theta]}$ (נסמן $(ij) \in [28]$) אלא $H = \{h_{ij} \mid ij \in [28]\} \cup \{-h_{ij} \mid ij \in [28]\}$ סיווג (ij) כהה סיווג (ij) כבהיר.

- דוגמה לשליטה: $\gamma = \{0, 1\}$, $\chi = \mathbb{R}^2$.

$B \subset H$: $H = \{f \mid f \text{ הוא פונקציה ב-} \mathbb{R}^2 \text{ שמתחלקת את המישור ל-2 חלקים}\}$ f הוא פונקציה ב- \mathbb{R}^2 שמתחלקת את המישור ל-2 חלקים. האם קיים אגז' f - γ -מודל חלש?



$[4,6] \times [6,8]$
label = 0
label = 1



f הוא פונקציה

לא! נסגור על ההתפלגות האחידה במרחב $[4,6] \times [6,8]$ שמתפלגת אחיד בריקון שמוצג בשאלה: אפשר למדוד אלא על במונה 2:

אך לא נים למדוד אלא על במונה 1: נניח בהכרח שה

למודל דפי חזר x_1 . במסגרת (חזר) הפונקציה: $h_{\theta_1}(x) = \mathbb{1}_{[x_1 > \theta_1]}$ θ_1 - θ_1 בשאלה. דוגמה: (ונרצה לקרוא משהו טוב יותר מניחוש ומחורגותינג: θ_1).

$$P(y=0 | x_1 > \theta_1) = P(y=0, x_1 < 5 | x_1 > \theta_1) + P(y=0, x_1 \geq 5 | x_1 > \theta_1) = P(x_2 \geq 7, x_1 < 5 | x_1 > \theta_1) + P(x_2 < 7, x_1 \geq 5 | x_1 > \theta_1) =$$

(θ_1 בהנחה θ_1 בשאלה) הסיכוי להיות $x_1 \leq 5$ - $x_2 \geq 7$ שווה לסיכוי להיות $x_1 \leq 5$ - $x_2 \leq 7$ כי אלו שני החלקים יש שטח זהה, על ידיהם ההתפלגות אחידה לכל המשוואות במרחב $[4,6] \times [6,8]$ כחל.

$$= P(x_2 < 7, x_1 < 5 | x_1 > \theta_1) + P(x_2 < 7, x_1 \geq 5 | x_1 > \theta_1) = \frac{1}{2} \left(= P(y=0 | x_1 < \theta_1) = P(y=0 | x_2 > \theta_2) = \dots \right)$$

לא משהו
אם \leq
אם $<$
כי אלו
בהתפלגות
כזו $P(y=t) = 0$

לכל $x \in \mathcal{X}$ D - δ האם ניתן למצוא?

$$L_{0,f}(h_{\theta_1}) = P(y \neq h_{\theta_1}(x)) = P(y=0, h_{\theta_1}(x)=1) + \\ + P(y=1, h_{\theta_1}(x)=0) = P(y=0, x_1 > \theta_1) + \\ + P(y=1, \theta_1 > x_1) \stackrel{(\text{דיון})}{=} P(y=0 | x_1 > \theta_1) P(x_1 > \theta_1) +$$

$$+ P(y=1 | x_1 < \theta_1) P(x_1 < \theta_1) = \frac{1}{2} P(x_1 > \theta_1) + \frac{1}{2} P(x_1 < \theta_1) = \\ = \frac{1}{2} [P(x_1 > \theta_1) + P(x_1 < \theta_1)] = \frac{1}{2} \cdot 1 = \frac{1}{2} \Rightarrow \text{כי} \quad \textcircled{!}$$

★ ניתן להוכיח דוגמה זו על \mathbb{R}^m בקלות.
★ המסקנה היא שההסתברות היא $\frac{1}{2}$

Adaboost ←

— האלגוריתם כמובן קובע את המרחב של θ —

★ המרחב של θ קובע את המרחב של θ ואת המרחב של θ .
כל ההסתברות θ שניתן להסתכל בה היא θ ואת θ .
למעשה קובע את θ ואת θ ואת θ .
★ (מחשוב θ D במידת מסקנות θ הנכונה).